

01 · 技术演进与本质

视角：从 2017 Transformer 到 2026 agentic 系统，逐个拐点拆解"底层范式"是什么、之前为什么做不到、之后什么变成可能。目标是建立一套"看到新模型/新名词能秒判断真本质 vs 工程包装"的认知滤镜。

一句话总览

LLM 八年的真演进，本质只发生过四件事：(1) 把序列建模并行化 (Transformer)；(2) 发现 loss 随规模可预测下降 (Scaling Laws)；(3) 把"对答案的奖励信号"接入预训练后的网络 (RLHF → o1/R1 的 RLVR)；(4) 把"模型说话"扩成"模型行动" (tool use → computer use → agent)。其余多数"突破"，要么是这四件事的衍生工程化，要么是产品包装；判断一项新技术是否"真本质"，看它有没有改变这四个轴中的至少一个。

关键句提纲

- **Transformer (2017)**：把"必须按时间步走"的递归换成"全部 token 同时算注意力"，让 GPU 吃满算力，规模化才成为可能。
- **Scaling Laws (Kaplan 2020)**：loss 是参数/数据/算力的幂律函数，跨 7 个数量级稳定；从此训模型从手艺变工程预测。
- **GPT-3 (2020)**：175B + few-shot 涌现 in-context learning，prompt 第一次取代 fine-tuning 成为接口。
- **Chinchilla (2022)**：参数和 token 应等比扩张；之前所有人都把模型做太大、数据喂太少。
- **CoT + Emergent Abilities (Wei 2022)**：让模型把推理链显式吐出来，多步任务首次可能；同时 Schaeffer 2023 警告"涌现"很多是评测指标的非线性假象。
- **InstructGPT / RLHF (2022)**：把"人类偏好"接入 fine-tune，第一次让对话产品可用，催生 ChatGPT。
- **GPT-4 / Claude 3 (2023-2024)**：多模态原生 + 长上下文，模型从"语言机"变成"视觉-语言-代码-工具"统一接口。

- **Function Calling (2023.6)** : 把"模型生成 JSON 调用外部 API"训成模型本身的能力，agent 时代地基。
- **o1 / R1 (2024-2025)** : 把 RL 的奖励信号从"人类喜欢"换成"答案对错" (RLVR) ，test-time compute 成为新的 scaling 维度。
- **Computer Use / Claude Code (2024-2025)** : 模型从"输出 token"扩到"操作屏幕和文件系统"，长 horizon agent 自治时长翻倍。
- 持续进化轴：context 长度、工具调用稳定性、agent 自治时长 (METR：每 4-7 个月翻倍)、可验证领域 (数学/代码) 能力。
- 周期性 / 边际递减轴：纯 pretraining loss 改进、benchmark 分数、模型尺寸单一指标、对话流畅度。

时间线深度展开

2017 · Transformer：把序列建模变成可并行的表示学习

Vaswani et al. Attention Is All You Need (NeurIPS 2017, arxiv 1706.03762)。RNN/LSTM 的根本瓶颈是"必须按时间步串行"——梯度沿时间反传，长序列梯度消失，且 GPU 用不满。

Transformer 的本质动作只有一个：用 self-attention 让序列里所有位置在一次矩阵乘法里互相看，计算图变成全并行。

这之前做不到的：在合理时间内训 100B 量级模型；学到长距依赖。之后变成可能的：把 NLP 当成"一个统一架构 + 大数据 + 大算力"的工程问题。Karpathy 在 2023 年 Intro to Large Language Models 里反复强调，Transformer 的真正意义不是"更聪明"，而是"可扩展到任意规模而不退化"。Noam Shazeer 一作之一 (multi-head attention 出自他手)，论文 2017 年发布时几乎没引爆，今天被引超 12.5 万次。

判断滤镜：任何宣称"取代 **Transformer**"的新架构 (**RWKV**、**Mamba**、**xLSTM** 等)，先问它有没有保留全并行 + 长距访问这两条；保不住至少其一，就还在做 **RNN** 的事。

2020 · GPT-3：scaling laws + in-context learning

Kaplan et al. Scaling Laws for Neural Language Models (arxiv 2001.08361)：跨 7 个数量级，loss 随参数 N、数据 D、算力 C 都是干净的幂律。Brown et al. Language Models are Few-Shot Learners (GPT-3, arxiv 2005.14165) 175B 参数在 prompt 里直接给几个例子就能做新任务，**in-context learning** 出场。

之前做不到的：看到一个新任务直接做，不用 fine-tune 数据。之后变成可能的：prompt 成为编程接口；"训一个大模型解决无限下游任务"的范式确立。

本质突破在哪？不是模型变聪明了，而是 **scaling** 的可预测性被证明了——你给 OpenAI/Anthropic/DeepMind 一笔钱，他们能算出 loss 会到几位小数。这把 LLM 从研究项目变成基础设施投资。

2022 · Chinchilla：算力最优分配

Hoffmann et al. Training Compute-Optimal Large Language Models (DeepMind, arxiv 2203.15556)。训 400+ 个模型后发现：Kaplan 法则给出的"参数比数据更值得加"是错的，参数和 **token** 应等比双倍。70B 的 Chinchilla 训 1.4T token，吊打 280B Gopher、175B GPT-3、530B MT-NLG。

含义：之前所有大模型都"太胖太瘦"——参数过多、token 不够。这条法则之后，Llama、Mistral、DeepSeek 都走"小参数 + 大 token"路线，今天最强开源模型的尺寸（7B-70B 活跃参数）是这条法则的直接产物。

2022.1 · CoT 与"涌现能力"

Wei et al. Chain-of-Thought Prompting Elicits Reasoning (arxiv 2201.11903)。在 prompt 里给"思考过程"示例，540B 模型在 GSM8K 上准确率从 18% 跳到 57%，超过 fine-tune + verifier 的 GPT-3。同年 Wei et al. Emergent Abilities of Large Language Models (arxiv 2206.07682)：某些能力在小模型上 0%，跨过某尺寸阈值后陡升。

之前做不到的：让模型把"中间步骤"作为可优化对象；多步算术。

但要注意 Schaeffer et al. 2023 Are Emergent Abilities a Mirage? (NeurIPS 2023 best paper runner-up)：很多"涌现"是因为研究者用了非线性指标（如 exact-match accuracy）；换成 token edit distance，曲线就是平滑的。涌现是真，但"突然出现"多半是测量假象——这是这套认知框架里最重要的"反热度"工具。

2022.3 · InstructGPT / RLHF：让模型听人话

Ouyang et al. Training language models to follow instructions with human feedback (arxiv 2203.02155)。三阶段：SFT → 训 reward model → PPO。1.3B InstructGPT 在人工评测里超过 175B GPT-3。100 倍参数差被对齐方法吃掉。

这才是 ChatGPT 能在 2022.11 起飞的真原因。GPT-3 在 2020 已存在，但"会聊天"这件事不是 scale 给的，是 RLHF 给的。Constitutional AI (Anthropic 2022) 后续把"人类标注"换成"模型按一组宪法原则自我批评"，DPO (Rafailov 2023) 干脆绕开 reward model 直接优化策略——alignment 工具栈在 2023-2024 演化得很快，但底层范式始终是"用偏好信号塑造 **base model**"。

2023 · GPT-4 / Claude : 多模态 + 长上下文

GPT-4 Technical Report (OpenAI 2023.3) ; Bubeck et al. Sparks of Artificial General Intelligence (Microsoft , arxiv 2303.12712) 声称 GPT-4 早期版本展现"AGI 的火花"——能在没特殊训练的情况下解决跨学科新颖任务。Anthropic Claude 3 Opus/Sonnet/Haiku (2024.3) 原生视觉 + 200K context。

本质突破：模型从单一模态扩到统一表示。图像 token 化后塞进同一个 Transformer，"看图说话"不再是 caption 模型 + 语言模型拼接。这条路径让 multimodal 不再是产品功能，而是基础能力。

2023.6 · Function Calling : 从"说话"到"做事"

OpenAI 2023 年 6 月把"调函数"做进 GPT-3.5/4 的训练目标里：模型学会判断什么时候该停止聊天、输出严格 JSON、等待外部结果再续接。11 月升级为 tools 参数支持多工具并行。这是 agent 时代的物理基础。

之前做不到的：稳定的工具调用——靠 prompt 工程让模型输出 JSON 总有 5-10% 失败率，没法跑生产。之后变成可能的：检索、计算、外部 API、代码执行成为模型的"延伸器官"。

2024 · 100K-2M 长上下文：工程化但有"context rot"

Gemini 1.5 Pro 上线 1M-2M token ; Claude 1M context 2026.3 GA ; Gemini 在 needle-in-haystack 上 >99.7% 召回。但 **Chroma 2025 Context Rot** 研究测了 18 个前沿模型 (GPT-4.1 / Claude Opus 4 / Gemini 2.5) ，发现所有模型在每个长度增量都有性能下降——"能记住"≠"能用"。这是 attention 的架构属性，不是数据问题。

判断滤镜：长 **context** ≠ 长记忆。看到"我家模型 10M context"先问 **needle** 多个 + 跨段推理的准确率。

2024.9-12 · o1 : test-time compute 成为新 scaling 轴

OpenAI o1 System Card (2024.9 / 12.5) 。Learning to reason with LLMs。本质：用大规模 **RL** 训练模型在内部生成更长的 **chain-of-thought**，奖励信号是"答案最终对不对"。性能在两个轴上都涨：训练时 RL 算力、推理时思考 token 数。Codeforces 89th percentile，AIME 平均 74% (单样本)。

为什么这是真本质？因为它打开了第二条 **scaling** 维度。pretraining 数据快用完 (Sutskever NeurIPS 2024：「数据是 AI 的化石燃料，我们已到 peak data」)，test-time compute 给了"越想越准"的新规模化方式。

2025.1 · DeepSeek R1 : 纯 RL 也能涌现推理

Guo et al. DeepSeek-R1: Incentivizing Reasoning Capability via Reinforcement Learning (arxiv 2501.12948, Nature 2025)。R1-Zero 完全跳过 **SFT**，只用 GRPO (Group Relative Policy Optimization, 去掉 critic 网络, 用同 prompt 多次 rollout 之间的相对优势) + 答案正确性这一个 reward，居然就涌现出自我反思、回退、验证这些行为——著名的「**Aha moment**」：训练曲线上某一刻模型突然学会说「等等，让我重新想想」。

这个发现颠覆了“必须先 SFT 才能 RL”的工程信条。开源 + 蒸馏出 1.5B-70B 一系列推理模型，几周内复现遍地开花，把 reasoning 能力的复制成本打到 50 美元 (李飞飞团队 s1, 蒸馏 Gemini 2.0 Flash Thinking)。

2024.10-2025 · Computer Use / Claude Code : 从输出到行动

Anthropic 2024.10 推出 Claude 3.5 Sonnet computer use beta：模型直接看屏幕截图、移动鼠标、敲键盘。Claude Code 2025 推出后，agent 单次自治会话长度在 3 个月内从 25 分钟翻到 45 分钟 (Anthropic 2026 Agentic Coding Trends Report)。METR 测得 AI 完成任务的“时长 horizon”2019-2025 每 7 个月翻倍，2024-2025 加速到每 4 个月。

本质：模型的输出空间从 “next token” 扩到 “next action on real world”。这一步比 function calling 大——function calling 是结构化输出，computer use 是连续控制。

2024 · Mechanistic Interpretability : 第一次看见 LLM 在想什么

Anthropic Towards Monosemanticity (2023.10) 和 Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet (2024.5)。用稀疏自编码器 (SAE) 在 Claude 3 Sonnet 残差流上抠出数千万个特征，70% 人类可解释，并能直接 steering 模型行为 (“金门大桥 Claude” 实验：把“金门大桥”特征 clamp 高，模型自称是金门大桥)。

这不是产品意义上的拐点，但是理解层面的拐点：之前我们对 LLM 内部完全黑箱，现在至少有了“分子生物学”——能定位概念在哪几个特征上、能做因果干预。后续 OpenAI 也跟上做 SAE 大模型化。

2025+ · 持续学习与 **memory** : 仍未解决

Anthropic 在 Claude 3.5/4 内置 persistent memory；OpenAI 给 ChatGPT Pro 加 cross-session memory (2024)；Mem0、A-Mem、FLEX 等学术系统层出不穷。但 MemoryArena benchmark 显示：在 LoCoMo (被动记忆 QA) 拿满分的系统，进入“记忆驱动决策”任务掉到 40-60%。

真本质突破还没发生。今天所谓的“memory”基本是 RAG + 工程 hack。Demis Hassabis 2024.12 直接说：**AGI 还差 continual learning、robust memory、introspective reasoning** 这三块——这些都是当前架构的结构性洞，不是 scale 能补的。

哪些是真本质？哪些是表象？

维度	类别	说明
架构并行性 (Transformer)	真本质（一次性）	一次完成，今天所有进步建立其上
Pretraining scale loss	持续但已边际递减	Kaplan→Chinchilla→数据墙；Orion 相对 GPT-4 进步远小于 GPT-3→GPT-4
In-context learning	真本质（一次性）	改变了交互范式，无法"再发现一次"
RLHF / 偏好对齐	真本质	让模型可用；DPO/CAI 都是工具变体
RLVR / 可验证奖励 (o1/R1)	真本质，且仍在扩张	打开 test-time compute 新轴；目前只在数学/代码这种"易验证"领域 work
Test-time compute	持续进化	thinking token 数、self-consistency、tree search 仍在涨
Context 长度（裸数字）	周期性/边际	1M tokens 是营销，真实可用约 100-200K，再长是 context rot
工具调用稳定性	持续进化	从 90% JSON 成功率到 99.5%+
Agent 自治时长	持续进化（ METR 每 4-7 月翻倍）	25 分钟 → 45 分钟，向小时级走
多模态融合	持续进化	文本/视觉/音频统一表示已成熟，视频和具身仍开放
模型参数尺寸单数字	已边际	MoE 后"总参数 vs 活跃参数"不能再单看；尺寸不是好指标
通用 benchmark 分数	快饱和	MMLU、HumanEval 已到天花板；ARC-AGI-2、Frontier Math、ARC-AGI-3（人 100% AI 0%）才有信号
解释性 / SAE feature	真本质（仍年轻）	第一次有"看见模型在想什么"的工具
Memory / 持续学习	未解决	当前都是工程 hack，结构性突破未发生

工程包装而非本质的典型例子

- **"Agent 框架"**层出不穷（AutoGPT, BabyAGI, CrewAI, ...）：底层全是 prompt + tool calling + while-loop；模型不变，框架不会让"agent 自治时长"突破。Anthropic 2024 Building effective agents 直说"大多数生产系统不需要 framework"。
- **"我家模型 1M/10M context"**：不配 needle-in-haystack 多针 + 跨段推理评测的，都是营销。
- **"思维链产品"**包一个 **prompt** 就喊 **reasoning model**：没有 RLVR 训练的，只是 CoT prompting，o1 那一档跳跃靠的是 RL 不是 prompt。

- **MoE** 总参数堆到万亿：单看总参数无意义，看活跃参数（active params）和路由质量。

不同立场和争议

Yann LeCun (Meta → 2025.11 离职创办 AMI Labs , 10 亿美金种子轮)

核心立场：自回归 LLM 是 dead end，不可能到达 human-level，更不用说 AGI。

理由：LLM 没有世界模型、不能做 grounded planning、没有持续学习。他的 JEPA / energy-based / objective-driven 路线主张"先建世界模型，再让 agent 在模型里规划"。X 原帖（2024.5）：「自回归 LLM 不足以达到人类级智能（甚至猫级智能也不行）」。

背景：他是连接主义 + 计算机视觉派，长期主张感官 grounded learning > 文本统计；Meta 投了多年 LeCun 路线但 Llama 系列证明 LLM 路径仍在涨，他出走某种程度是路线之争。

Sutskever (OpenAI → SSI) / Hinton

核心立场：scaling 路径还远未饱和，但形态会变——下一代是 agentic + reasoning + 自我意识系统。

理由：NeurIPS 2024 演讲明确"pre-training as we know it will end"（不是说 **scaling** 死了，是说 **pretraining** 这个具体实现方式到顶了），但 inference-time compute、agents、合成数据是新疆域。"我们已到 peak data"是核心论断。

背景：他亲自写了大部分 OpenAI scaling 论文，2023 年起转 alignment / superintelligence 长视角。

Gary Marcus

核心立场：推理是结构性问题，scale 永远解决不了。

理由：从 1998 年起就论证神经网络在分布外泛化失败；指 Apple 2024 GSM-Symbolic 论文（轻微改写题目就崩）作为"知识盲打"。认为 LLM 没有显式符号系统、没有可点查的世界模型。即使 o1/R1 这种 reasoning model，他认为只是"在分布内推理变好了"。

背景：神经符号融合派（neuro-symbolic），与 LeCun 共享"LLM 不够"的判断但路线不同——Marcus 主张混合显式符号，LeCun 主张 self-supervised 视觉/世界模型。

Anthropic / Dario Amodei

核心立场：alignment 与能力联合演进才是关键；powerful AI 2026-2030 大概率到来。

理由：Machines of Loving Grace (2024.10)：powerful AI 的定义比 AGI 操作化 ("a country of geniuses in a datacenter")，预测 5-10 年内可压缩"21 世纪生物医学进展"。但前提是 interpretability + 可控的 RL 推理一起做。

背景：他是 GPT-2/3 scaling 论文的合著者，对 scaling 信念深，但出走 OpenAI 创立 Anthropic 就是因为相信"光 scale 会出事"，必须 alignment first。

Demis Hassabis (DeepMind)

核心立场：AGI 来自 LLM + RL + search + world model 的混合架构；2030 前 50/50 概率到达。

理由：DeepMind 血统是 AlphaGo/AlphaZero 那条 search + RL 路线。Hassabis 反复说"missing 1-2 big ideas"，明确指 continual learning、memory、introspective reasoning。Genie 2/3 做可控世界模拟环境，让 embodied agent 先在虚拟里学。

背景：神经科学博士，认为生物大脑是 existence proof，AGI 要从神经科学借蓝图（海马体记忆、皮层世界模型、基底节 RL）。

第六派加分：François Chollet (ARC Prize)

核心立场：智能不是知识量，是新任务的 **skill-acquisition efficiency**。

理由：ARC-AGI-2 上纯 LLM 0%，前沿 reasoning system 单数字百分比，人类很高。ARC-AGI-3 video-game 风格人 100% / AI 0%。这说明现有路径没在测真泛化，benchmark 进步多半是分布内。

前瞻假设 (5 条可验证)

1. 2026 内至少一家头部实验室发布纯非文本预训练的世界模型 + LLM 混合系统（视频/3D 仿真原生），benchmark 在 ARC-AGI-3 类任务上从 0% 跳到两位数。证伪条件：到 2026.12 仍是文本-only 模型小修小补。
2. 2027 前长 horizon agent 自治时长（METR 50% 成功率口径）突破8 小时——按当前每 4 个月翻倍外推。证伪条件：2027.6 仍卡在 1-2 小时台。
3. 持续学习至少一种工程上可用方案在 2026-2027 出现（不是简单 RAG，能在多 session 做参数级更新且不灾难性遗忘）。证伪条件：到 2027.6 仍只有"扩大 context + 向量库"路线。
4. **RLVR** 跨域：可验证奖励训练扩到目前 verify 难的领域（开放写作、设计判断、科研假设）的可信信号在 2026 出现，靠的是 reward model + 自博弈或多 agent 互查；证伪条件：到 2026.12 仍只有数学/代码这两类受益。

5. **Pretraining** 端单纯 **scale loss** 改进 在 2026 公开模型上不再带来前端能力质变（仍降 loss，但 benchmark/真实任务无显著跃升），所有跃升来自 RL/agentive/inference compute。证伪条件：2026 出现一个纯 scale-up 模型在通用 benchmark 上重现 GPT-3→GPT-4 量级跳跃。
-

Mermaid 脑图

思维导图 (Mermaid 源)

```
mindmap
  root((LLM 技术本质))
    四件真发生的事
      并行化序列建模
        Transformer 2017
      可预测的规模化
        Kaplan 2020
        Chinchilla 2022
      接入正确性奖励
        RLHF 2022
        RLVR o1 R1 2024 2025
      从输出到行动
        Function Calling 2023
        Computer Use 2024
        Claude Code 2025
    持续进化轴
      工具调用稳定性
        agent 自治时长 METR
        test-time compute thinking
      可验证领域能力
      解释性 SAE
    周期性边际递减
      pretraining loss 改进
      参数尺寸单数字
        MMLU 类 benchmark
      context 长度营销数字
    未解决结构洞
      持续学习
        robust memory
      跨域可验证奖励
      真泛化 ARC-AGI
    争议节点
      LeCun LLM 死路
      Sutskever pretrain 见顶
      Marcus 推理结构性
      Amodei 对齐+能力
      Hassabis RL+search 混合
      Chollet 智能=新任务效率
    判断滤镜
      看是否动了四轴之一
      看 benchmark 是否真泛化
      看 needle 多针长 context
      看 active params 而非总参数
```

完整图形渲染请查看 [HTML 版本](#)。

来源库（按重要性）

类型	标题	作者/机构	日期	链接	
论文	Attention Is All You Need	Vaswani, Shazeer et al. (Google Brain)	2017.6	https://arxiv.org/abs/1706.03762	Transformer
论文	Scaling Laws for Neural Language Models	Kaplan, McCandlish, Amodei et al. (OpenAI)	2020.1	https://arxiv.org/abs/2001.08361	Scaling Laws
论文	Language Models are Few-Shot Learners (GPT-3)	Brown et al. (OpenAI)	2020.5	https://arxiv.org/abs/2005.14165	GPT-3
论文	Training Compute-Optimal LLMs (Chinchilla)	Hoffmann et al. (DeepMind)	2022.3	https://arxiv.org/abs/2203.15556	Chinchilla
论文	Chain-of-Thought Prompting	Wei et al. (Google)	2022.1	https://arxiv.org/abs/2201.11903	CoT
论文	Emergent Abilities of LLMs	Wei et al. (Google)	2022.6	https://arxiv.org/abs/2206.07682	Emergent Abilities
论文	Training LMs to Follow Instructions w/ Human Feedback (InstructGPT)	Ouyang et al. (OpenAI)	2022.3	https://arxiv.org/abs/2203.02155	InstructGPT
论文	Sparks of Artificial General Intelligence	Bubeck et al. (Microsoft)	2023.3	https://arxiv.org/abs/2303.12712	Sparks of AGI
论文	Are Emergent Abilities a Mirage?	Schaeffer, Miranda, Koyejo (Stanford)	2023.4	https://arxiv.org/abs/2304.15004	Are Emergent Abilities a Mirage?
论文	DeepSeek-R1: Incentivizing Reasoning via RL	DeepSeek	2025.1	https://arxiv.org/abs/2501.12948	DeepSeek-R1

类型	标题	作者/机构	日期	链接	
文档	OpenAI o1 System Card	OpenAI	2024.9 / 12.5	https://cdn.openai.com/o1-system-card-20241205.pdf	t C 新
博文	Learning to reason with LLMs	OpenAI	2024.9	https://openai.com/index/learning-to-reason-with-llms/	C 官
博文	Towards Monosemanticity	Anthropic	2023.10	https://transformer-circuits.pub/2023/monosemantic-features/	和 C I
博文	Scaling Monosemanticity (Claude 3 Sonnet)	Anthropic	2024.5	https://transformer-circuits.pub/2024/scaling-monosemanticity/	二 金 C S
博文	Introducing Computer Use & Claude 3.5 Sonnet	Anthropic	2024.10	https://www.anthropic.com/news/3-5-models-and-computer-use	林 月
博文	Measuring AI Ability to Complete Long Tasks	METR	2025.3	https://metr.org/blog/2025-03-19-measuring-ai-ability-to-complete-long-tasks/	何 H 7
博文	Context Rot: Increasing Input Tokens Impacts Performance	Chroma Research	2025	https://www.trychroma.com/research/context-rot	1 全 C
文章	Machines of Loving Grace	Dario Amodei	2024.10	https://www.darioamodei.com/essay/machines-of-loving-grace	" G C 2 间
演讲	Sequence to Sequence Learning: What a Decade	Ilya Sutskever	NeurIPS 2024.12	https://www.youtube.com/watch?v=1yvBqasHLZs	" a v P
演讲	Software Is Changing (Again) / Software 3.0	Andrej Karpathy	YC AI School 2025.6	https://www.latent.space/p/s3	1 林 P

类型	标题	作者/机构	日期	链接	
博文	2025 LLM Year in Review	Andrej Karpathy	2025.12	https://karpathy.bearblog.dev/year-in-review-2025/	"G...n...a...j...i"
视频	Intro to Large Language Models	Andrej Karpathy	2023.11	https://www.youtube.com/watch?v=zjkBMFhNj_g	L...o...F
访谈	Demis Hassabis on Dwarkesh Patel	Hassabis x Patel	2024	https://www.dwarkesh.com/p/demis-hassabis	A...<
论文	DeepSeekMoE: Towards Ultimate Expert Specialization	DeepSeek	2024.1	https://arxiv.org/abs/2401.06066	终...共...跟
论文	ARC-AGI-2: Challenge for Frontier AI Reasoning	Chollet et al.	2025.5	https://arxiv.org/abs/2505.11831	L...n...s...5
报告	2026 Agentic Coding Trends Report	Anthropic	2026	https://resources.anthropic.com/hubfs/2026%20Agentic%20Coding%20Trends%20Report.pdf	C...自...2
X/分析	LeCun: Auto-Regressive LLMs are insufficient	Yann LeCun	2024.5	https://x.com/ylecun/status/1793680385403957295	L...l...o...c
博文	A Knockout Blow for LLMs?	Gary Marcus	2024	https://garymarcus.substack.com/p/a-knockout-blow-for-llms	持...子...H...外
中文	从 o1-mini 到 DeepSeek-R1 : 推理模型的历史与技术	机器之心编译	2025.2	https://zhuanlan.zhihu.com/p/25978555277	持...中
中文	Karpathy 软件 3.0 演讲全文	36kr / 腾讯新闻	2025.6	https://36kr.com/p/3344734734566016	中

类型	标题	作者/机构	日期	链接	
博文	Reverse engineering OpenAI's o1	Nathan Lambert (Interconnects)	2024.9	https://www.interconnects.ai/p/reverse-engineering-openai-o1	反工程
博文	Notes on o1 chain-of-thought models	Simon Willison	2024.9	https://simonwillison.net/2024/Sep/12/openai-o1/	思考链

终极判断滤镜（一页式）

看到任何"新模型/新技术"，按这五问过：

1. 它动了上面四件真本质中的哪一件？（架构并行性 / 可预测 scaling / 接入正确性奖励 / 输出→行动）。一件没动，多半是工程包装。
2. 它的 **benchmark** 是不是真泛化？MMLU、HumanEval 已饱和不能用了；看 ARC-AGI-2/3、Frontier Math、SWE-bench Verified、METR 长 horizon。
3. 它给出的 **context** / 参数 / 时长数字背后真实可用比例多少？Needle 多针、active params、50% 成功率口径，三个去掉一个就警觉。
4. 它解决了 **LeCun/Marcus/Hassabis** 共同指出的结构洞了吗？持续学习、robust memory、真泛化、世界模型。没解决，再强也是当前曲线上的及格。
5. 它的提升是来自 **pretraining loss** 还是 **RL/agentive/inference compute**？后者还有空间，前者已边际递减。

完稿 2026.5.10 · 主要参照 Anthropic / OpenAI / DeepMind / Karpathy / Sutskever / LeCun / Marcus / Chollet / Anthropic Interpretability / METR / Chroma / DeepSeek 一手材料