

05 · 投资与商业模式

视角：钱往哪流、谁会赢、定价模式怎么变、护城河长什么样

写作时间：2026 年 5 月

关键词：价值链分层 · wrapper trap · outcome-based · vertical AI · \$600B question

一句话总览

AI 价值链的利润分布正在发生十年一遇的重排：基础设施层短期暴利但承受估值与折旧风险；模型层从「会被商品化」反转为「越往 **agent** 走越能整合赚厚利润」；应用层不再是 **wrapper** 笑话，而是分化成「死掉的薄壳」和「带着 workflow 锁定与数据 **flywheel** 的厚壳」两极。投资人能赚到钱的姿势只有四种：(1) 押 picks-and-shovels (Nvidia/CoreWeave/电力/HBM)；(2) 押模型 + 应用一体化 (OpenAI/Anthropic 直接做 ChatGPT 与 Claude Code)；(3) 押有真实 workflow 嵌入的 vertical AI (Cursor/Harvey/Glean/Perplexity)；(4) 押「AI native 替代现有 SaaS 巨头」的反叛叙事。SaaS 的 per-seat 定价正被 outcome-based / token-metered / per-action 打成筛子，Salesforce 同时挂出三种价格表已是公开承认。

关键句提纲 (10 条)

1. **Nvidia FY2026** 全年营收 \$215.9B、毛利率 71%、数据中心同比 +75%。这不是泡沫的描述，这是泡沫尚未破裂的描述——两者并不矛盾。
2. **OpenAI 25B+** 年化 / **Anthropic 30B** 年化 (均为 2026 **Q1** 数据)，三年内从零跑到 SaaS 用 20 年才到达的规模——但烧钱速度同样夸张，OpenAI 上半年 burn \$9.7B。
3. **David Cahn** 的「\$600B question」从 2024 年的 \$200B 缺口翻三倍——基础设施投资与终端价值之间的剪刀差仍在扩大，但 OpenAI/Anthropic 营收曲线给了乐观派更多弹药。
4. **wrapper trap** 是真的，但反例同样真。Cursor 12 个月从 \$100M ARR 跑到 \$1B+，Harvey 从 \$100M 到 \$190M ARR + \$11B 估值，Glean 9 个月翻倍到 \$200M ARR——薄壳死于 80% 比例，厚壳估值溢价 9-12x ARR。
5. **per-seat is dying**。Salesforce 同时支持 per-user / per-conversation (\$2)/per-action (Flex Credits, \$0.10) 三套定价，标志企业软件迈入 outcome-based。

6. **DeepSeek** 震撼一夜抹去 **Nvidia \$590B** 市值，但事后 SemiAnalysis 揭穿其实际硬件投入约 \$1.6B、50,000 张 Hopper——叙事比数据跑得快得多，这本身就是投资机会。
 7. **Ben Thompson** 反转关键洞察：模型商品化 → 应用层捡便宜 → 但模型公司向下做应用（ChatGPT/Claude Code）整合后利润反而比预期更高。Aggregation Theory 让位 Integration Theory。
 8. **Vertical AI** 估值 9-12x **ARR vs 传统 SaaS 5-7x**，Bessemer Cloud 100 名单 AI 公司占总估值 42%（创历史新高）。
 9. **MSFT Copilot** 在 4.5 亿商业订阅里只渗透 3.3%（1500 万付费 **seats**），市场份额从 18.8% 跌到 11.5%——巨头分发优势没有想象中那么自动转化为胜势。
 10. **AI capex 2025 ~\$500B、2026 预计逼近 \$700B**——这是科技史上最大的一次资本支出。即便 ROI 兑现，回报周期也会以 5-10 年计算。
-

AI 价值链分层（含利润分布预测）

层	代表玩家	当前利润 (2025-26)	5 年后预测	主要护城河	风险点
能源 / 电力	NextEra、Vistra、Constellation、SMR 玩家	中等，电网瓶颈推高现货价	极厚：被严重低估，AI 数据中心耗电将进入电网长期赤字	物理资产、地理稀缺、监管	电改政策、SMR 落地不及预期
晶圆代工	TSMC、三星、Intel Foundry	TSMC 一家独大、毛利 50% +	厚：AI 芯片几乎全在 TSMC，CoWoS 封装是真正瓶颈	工艺代差、CoWoS 产能	地缘、台海、3nm 以下良率
HBM / 存储	SK Hynix、三星、美光	极厚：HBM3E 满产、价格垂直拉升	厚但价格回归：扩产周期 18-24 月	良率工艺、长期合约绑定	扩产过剩
AI 芯片	Nvidia (~92%)、AMD、Google TPU、AWS Trainium、Cerebras、Groq (被 Nvidia \$20B 收编)	Nvidia 一家通吃，毛利 75%	份额下降至 70-75%，但绝对值仍涨	CUDA 生态、NVLink、整机柜系统	客户自研 ASIC、推理迁移
云 / GPU 租赁	AWS、Azure、GCP、Oracle、CoreWeave、Lambda	厚：Azure +33%、AWS 重新加速	厚但分化：超大规模云 + 专用 AI 云双轨	资本壁垒、网络效应、捆绑	折旧、利用率波动
基础模型	OpenAI、Anthropic、Google DeepMind、xAI、Meta、DeepSeek、Mistral、月之暗面、智谱、阿里通义、字节豆包	高营收但高烧钱；OpenAI/Anthropic 营收 2025-26 翻 5-15 倍	头部 3-5 家整合下沉做应用，长尾被开源吞噬	算力、数据、人才、品牌、Agent 整合	模型商品化、Capex 黑洞
Middleware / 工具链	LangChain、Pinecone、Weaviate、LlamaIndex、Modal、Replicate、Hugging Face	弱：被模型方/云方挤压	多数被吞并/边缘化，少数作为 MCP 标准基础设施	开源社区、生态绑定	大厂下场、协议被 OpenAI/Anthropic 标准化
应用层 / vertical AI	Cursor、Perplexity、Harvey、Glean、Notion、Granola、ElevenLabs、Suno、	两极：薄壳 80% 死亡，厚壳 ARR 飞起	赢家显著扩张：3-5 个 vertical 跑	workflow 锁定、数据 flywheel、品	模型方下沉、巨头跟进、token 成本

层	代表玩家	当前利润 (2025-26)	5 年后预测	主要护城河	风险点
	Lovable、Cognition、Replit、Hebbia		出 \$10B+ 公司	牌、distribution	
服务 / 集成	Accenture、Deloitte、TCS、Infosys；新型 AI 实施商	暴利：传统 IT 服务厂商靠咨询费收割	厚但人头被替代	客户关系、合规、垂直经验	AI agent 取代咨询师

利润迁移核心判断：

- 2024-2026：基础设施层最赚钱（Nvidia 是最大赢家），上层都在烧钱；
- 2026-2028：模型层与应用层同时整合，OpenAI/Anthropic 学会用应用赚钱，Cursor/Harvey 学会用模型省钱；
- 2028+：能源 + 工艺 + vertical AI + agent 服务化构成新格局，Nvidia 份额回落但绝对利润不减。

应用层 vs 模型层 vs 基础设施层：博弈分析

三种主流叙事

- 叙事 **A**：应用层会赢（**a16z / Sarah Wang / Sonya Huang**）
- 模型商品化趋势确定，剩下的差异化在用户体验、数据、工作流。
 - a16z 的 Top 100 Gen AI Consumer Apps（第 6 版，2026 年 3 月）显示 ChatGPT 仍是 2.7x 第二名 Gemini，但 Lovable / Cursor / Bolt / Manus / Genspark 等垂直 agent 起势——证明在某个具体场景里击败 ChatGPT 并不困难。
- 叙事 **B**：模型层会赢（**Ben Thompson 修正版**）
- 当 agent 需要 model-harness 紧密集成时，OpenAI 与 Anthropic 的「模型 + Agent + 应用」一体化反而是不可分的整合产品。
 - 数据点：Anthropic 在 2025 年 5 月才把 Claude Code 推到 GA，到 2026 年 2 月已是 \$2.5B 年化。这不是 wrapper，这是模型公司亲手做的应用并直接吃下利润。
- 叙事 **C**：基础设施会赢（**Brad Gerstner / Bill Gurley / 跟进 Nvidia 派**）
- 「AI is the trade of the decade」，资本支出 2025 年 \$500B、2026 年逼近 \$700B 已经锁定。
 - Altimeter 减仓 MSFT、加仓 Nvidia + SK Hynix + CoreWeave + Bloom Energy（电力），反

映「工具与原材料」思路。

- 风险：折旧周期被低估。Nvidia GPU 实际有用寿命 3-4 年，但折旧通常按 5-6 年算，hyperscaler 财报隐藏未来减值。

我的综合判断

短期（1-2 年）：叙事 C 继续兑现。Nvidia 加 SK Hynix 加 TSMC 仍是最稳的赚钱路径。

中期（2-4 年）：叙事 B 占上风。模型公司向下做应用，整合利润 > 纯模型 API 利润。

长期（4-7 年）：叙事 A 在垂直领域兑现，少数厚壳 vertical AI 跑出 \$10B+ 营收，薄壳几乎全死。

wrapper trap：真伪与例外

「你只是个 GPT wrapper」是 2023-2024 年最致命的 VC dismiss。但 2025-2026 年事实给了反例：

公司	ARR 增长	估值跳跃	它「不只是 wrapper」的关键
Cursor / Anysphere	\$100M (2025-01) → \$500M (06) → \$1B (11) → \$2B (2026-02)	\$2.5B → \$9.9B → \$29.3B → 谈判 \$50B+	自研代码检索 / 多文件编辑基础设施、定制 inference 栈、留存率 90%+ NDR、在程序员日常工作流中长出 daily-active 习惯
Harvey	\$100M (2025-08) → \$190M (2026-01)	\$3B → \$5B → \$8B → \$11B	嵌入 AmLaw 100 法律工作流、\$150M Azure 承诺、合规与企业安全姿态、专业培训 + 客户数据闭环
Perplexity	<\$100M (2025-03) → \$232M (2025) → \$500M (2026-04)	\$14B → \$18B → \$20B → \$21B	自研搜索索引、检索基础设施、答案合成 pipeline、Computer agent 产品扩展
Glean	\$100M (2025-03) → \$200M (12)	\$4.6B → \$7.2B	企业知识图谱、20T+ tokens 年消耗、千万级 ACV 客户翻三倍、统一模型 hub
Cognition / Devin	不公开	\$4B+	自主 agent 框架 + 自研模型
Granola	高增长（私募）	数亿美金	会议笔记 vertical 工作流、上下文 + 个性化记忆

关键判断：被低估的一个洞察是——「wrapper」与否的真正分界线不是「有没有自研模型」，而是「有没有用户每天打开它工作的不可替代理由」。Cursor 没有自己的 LLM，但程序员每天工作 8 小时离不开它，这就是护城河。

80% 死掉的薄壳通病：(1) 没有数据飞轮；(2) 没有工作流深度集成；(3) 没有专有训练或微调；(4) 价格可被 ChatGPT/Claude 直接吃下；(5) 留存率低于 80% NDR。

AI 时代的护城河新分类

护城河类型	含义	典型代表	投资可识别信号
数据 flywheel	用户用得越多，专有数据越多，模型越好	Tesla（自驾）、Bloomberg AI、Harvey、Replit	数据采集合约、数据回流频率、专有 RLHF 标注
workflow lock-in	嵌入用户日常工作流，离开成本极高	Cursor、Glean、Notion AI、Granola	DAU/MAU > 60%、NDR > 120%
distribution （已有用户基数）	直接把 AI 推给已存在的几亿用户	Microsoft (Office)、Google (Workspace)、Apple、字节、阿里	渠道独占、捆绑销售比例
品牌 / 信任	在敏感场景中是默认选项	OpenAI（消费者）、Anthropic（企业 / 编程）	Brand search volume、API 默认占比
合规 / 监管	受监管行业（金融、医疗、法律）需要审计、合规、地区数据驻留	Harvey、Hippocratic AI、OpenEvidence、Glean	SOC2 / HIPAA / FedRAMP 等认证、央企 / 监管行业客户名单
vertical 模型 + 应用一体化	垂直行业自研专用模型 + 整合应用	Perplexity 搜索栈、Cognition Devin、Tesla FSD	自有训练数据、垂直 benchmark 领先
网络效应	多边市场（生成内容流通）	Suno（音乐）、Midjourney、Lovable、Civitai	内容 / 模板 / Agent 互相调用次数
Cost / 算力效率	同等质量更便宜（DeepSeek 打法）	DeepSeek、Mistral、Cerebras inference	\$/token 对比、同 benchmark 价格优势

最危险的「假护城河」：单纯的 **prompt** 工程、**UI** 美观、垂直数据集（无飞轮）——这些都能在 6 周内被复制。

定价模式革命：per-seat 之死

旧模式：**per-seat**（核心 **SaaS** 时代）

- Salesforce、Workday、ServiceNow、Atlassian、Slack 用 20 年训练买家：每个员工每月固定订阅。
- 边际成本极低，毛利 75-85%。

新模式：outcome-based / per-action / per-token / success fee

案例	旧定价	新定价	价格信号
Salesforce Agentforce	per user \$50-200/月	\$2 / 对话 + Flex Credits (\$0.10/ action)	同时挂三种
Intercom Fin	per seat	\$0.99 / 解决的客服会话	success fee
Zendesk AI Agents	per agent	per resolution	outcome-based
GitHub Copilot	\$19-39 / seat / 月	加上 premium request usage (2025 起)	混合 metered
Microsoft 365 Copilot	\$30 / seat / 月	2026 涨价 + 引入 agent action 计费	seat + metered
Anthropic Claude Code	per seat 订阅	+ token usage (重度用户实际花费数百 / 月)	effectively token-metered
OpenAI ChatGPT	\$20 Plus / \$200 Pro	2026 引入 agent action 与 metered Sora 配额	seat + metered
Cursor	\$20-200 seat	高耗用户 over-usage 加价	seat + metered

为什么 per-seat 必然崩塌

1. **AI agent** 数量将远超人类员工 (Aaron Levie : 100x ~ 1000x agents) —— per-seat 单位的逻辑前提不复存在。
2. **Token** 是真实成本中心——客户耗费弹性极大 (重度用户 100x 普通用户) 。
3. **Outcome** 是真实价值锚点——CFO 不愿为「使用了 AI」付费，只愿为「关掉了 5 个客服坐席」付费。
4. **AI native** 公司天然按 **token / action** 卖——形成竞争压力。

财务后果

- 收入预测变难：MRR / ARR 不再是稳定数列，更像消费品。
- 毛利率结构：模型 token 成本是真实 COGS，毛利从 75-85% 降到 50-70%。
- 估值倍数：成长性 > 稳定性，但留存性会被更严格审视。

AI-native vs 现有巨头：谁稳谁危

看起来稳的 (**distribution + capital + data** 三件套都有)

- **Microsoft** : Azure +33%、与 OpenAI 关系即便重谈仍是优势，但 Copilot 渗透 3.3% 是警示——分发不等于胜利。评级：稳但被高估。
- **Google** : 模型自研能力顶级 (Gemini)、TPU、Search + YouTube + Workspace + Android 五大资产、Waymo 隐藏期权。Gemini 付费用户 +258% YoY。评级：被严重低估的真正赢家之一。
- **Apple** : Apple Intelligence 推迟 + Siri 改造缓慢，但终端分发 + 隐私品牌 + 自研芯片让它在 on-device AI 与隐私 agent 仍有战略空间。评级：观望，2026-2027 必须证明。
- **Meta** : Llama 开源策略 + 推荐系统 AI + Reality Labs。Threads / Instagram 内嵌 AI、广告系统效率持续提升。评级：稳，被低估的 **AI** 玩家。
- **Amazon** : Bedrock 模型选择权、Anthropic 重金投资 + Trainium 芯片、AWS 持续放量。评级：稳。
- **Nvidia** : 见后文。

危险区：被 **AI native** 反叛的传统 **SaaS**

- **Salesforce** : Agentforce 三套价格混乱说明它在被颠覆而非定义。AI native CRM (Attio、Clay、Day.AI) 从下蚕食。评级：中危。
 - **Workday / SAP** : HRIS / ERP 在 AI agent 自动化时代护城河变薄，但合规与数据深度仍是壁垒。评级：中危但有防御。
 - **ServiceNow** : 作为「企业自动化平台」反而在 agent 时代受益 (成为 agent 调用的底层工作流引擎)。评级：稳。
 - **Adobe** : Firefly 用「合规训练数据」差异化是聪明的姿态，但被 Midjourney / Sora / Runway 从消费侧蚕食，专业用户群仍稳。评级：中危。
 - **Atlassian / Slack** : 协作类被 Notion AI / Granola / Linear 等 AI native 全面挤压。评级：危。
 - **Intuit** / 财务软件：被 AI agent 自动化记账与报税严重威胁。评级：危。
 - 教育 / **Chegg / Duolingo** : Chegg 已遭 ChatGPT 直接屠杀，Duolingo 正反向用 AI。评级：分化。
-

模型公司商业模式

OpenAI

- 2026 年 4 月年化营收 \$25**B+**，2024 年仅 \$6B。
- 收入结构：消费者订阅（ChatGPT Plus/Pro/Enterprise，5000 万 + 付费用户）约 60%、API 约 30%、Enterprise + Agents + Sora 等约 10%（向 50/50 演进）。
- 路径：**ChatGPT → Operator/Agents → Sora → Apps Store**，在做「AI OS」。
- 真问题：毛利仍为负或低；2025 上半年 burn \$9.7B；预计 2029 年累计烧 \$115B。靠 SoftBank/Stargate 输血。
- 最大的潜在变现：广告（如「The Information」泄露讨论）。

Anthropic

- 2026 年 4 月年化 \$30**B**（已超 OpenAI）；从 \$1B（2024-12）→ \$9B（2025-12）→ \$30B（2026-04）。
- 收入结构：**API + 企业 70%+**，**Claude Code** 单独 \$2.5**B** 年化，消费者订阅 20% 不到。
- 路径：「企业级 + 编程 + 安全」三角，Claude Code 是飞轮放大器。
- 关键差异：训练成本约为 OpenAI 的 1/4（依其披露），毛利更健康。
- 风险：消费者品牌仍弱、对 AWS / GCP 双云依赖。

xAI

- Grok 与 X 平台原生整合 + Tesla / Optimus 数据。
- Colossus 孟菲斯训练集群是单点最大 GPU 集群（H100/H200/B200 量级）。
- 估值近 \$200B，营收尚不透明，更多是叙事溢价。

Meta (Llama 系)

- 不卖 API，把开源作为防御性策略——目的是防止被锁在 OpenAI / Anthropic 之外。
- 最终变现：广告系统效率提升 + Reality Labs Agent 助手。

Mistral / Cohere / Inflection

- Mistral：欧洲合规叙事 + 开源旗帜，估值约 \$14B。
- Cohere：企业 RAG 与知识库定位，被 Glean/Anthropic/OpenAI 夹击。
- Inflection：被 Microsoft 实质 acqui-hire，已退出第一线。

DeepSeek（杭州）

- V3/R1 让世界震惊；但实际硬件投入约 \$1.6B、50,000 张 Hopper GPU。
- 没有商业化压力（量化投资母公司输血），开源策略本身是地缘工具。
- 影响最大：把行业 token 价格降低一个数量级，倒逼所有人重写成本曲线。

中国头部（详见下节）

Nvidia 与硬件投资

当下数据（FY2026 全年，截至 2026 年 1 月）

- 营收 \$215.9B（+65% YoY），数据中心 \$62.3B 单季（+75% YoY）
- GAAP 毛利率 71.1%，单季达 75%
- 净利润 ~\$43B 单季
- Blackwell（B200/GB200）满载，Rubin（R100）2026 年下半年量产

一家通吃可持续吗？

支撑因素：

- CUDA 生态：60 万 + 开发者锁定，所有顶级 AI lab 训练栈都长在 CUDA 上。
- NVLink + 整机柜系统：Nvidia 已从「卖芯片」上升到「卖整柜数据中心」（GB200 NVL72）。
- 软件栈：Triton、TensorRT、NIM 微服务、Omniverse、Cosmos 模型库——每一层都是钉子。
- \$20B 收购 Groq（2025 年底）：把推理优化威胁内部消化。

威胁因素：

- **AMD MI300/MI350/MI450**：Meta + OpenAI 都签了 6 GW 部署协议。AMD 数据中心 AI 增长率预测 +80% CAGR。
- **Custom ASIC**：Google TPU、AWS Trainium、Microsoft Maia、Meta MTIA 都在大规模量产；ASIC 出货 +44.6% YoY，远超 GPU +16.1%。
- **Cerebras**：晶圆级芯片在某些大模型推理上 2x 速度，已与 OpenAI 签 \$20B 协议、\$23B 估值申请 IPO。
- 新一代推理专用：Groq（被收）、Etched、Tenstorrent、SambaNova。
- **DeepSeek** 类训练效率优化：让全行业重新审视「堆 GPU 是否过度」。
- 客户自研：所有 hyperscaler 都不希望 Nvidia 拿走 30-40% 的总 capex。

5 年判断：Nvidia 总营收继续增长（绝对值），市占从 92% 降到 70-75%，毛利从 75% 回到 60-65%。仍是最大 winner，但「一家通吃」叙事会被「Nvidia + 三家强 ASIC + 两家强 GPU 替代」的多极格局取代。

Picks-and-shovels 衍生赢家

- **TSMC**：3nm/2nm + CoWoS 先进封装垄断。AI 芯片最大隐形赢家。
- **ASML**：EUV 光刻机独家。
- **SK Hynix / Micron / Samsung**：HBM 是真正瓶颈。
- **CoreWeave / Lambda / Crusoe**：GPU-as-a-service 暴利期。
- **Vertiv / Schneider / Eaton**：液冷与电力管理。
- **Constellation / Vistra / NextEra** / 核电与 **SMR**：电力是终极瓶颈。

中国 AI 投资格局

三大势力

1. 大厂派

- 阿里通义 **Qwen**：开源 + 云业务（阿里云 AI 收入连续 6 季三位数增长）；估值方面，阿里整体被重估为中国最大 AI 受益者。
- 字节豆包 / **Doubao**：To C 月活 1.4 亿+，Kimi 之后中国第一；产品层面已逼近 ChatGPT 国内体感；变现靠抖音生态。
- 腾讯混元 + 微信 **AI**：分发优势顶级，但产品速度慢于字节、阿里。
- 百度文心：跟跑，差距拉大。

2. 六小龙 / **Six Tigers**（融资烧钱期已结束，分化加剧）

- **DeepSeek**：开源旗手，量化母公司输血、不缺钱、不上市，价格屠夫。
- **Moonshot** 月之暗面：Kimi 是消费者第二，长上下文路线，2024-25 年高峰已过、用户与日活波动。
- **Zhipu** / 智谱 **AI**：To B 强、ChatGLM 系列；2025 上市路径明确但 GPU 受限风险大。
- **Minimax**：Talkie 海外消费应用 ARR 约 \$70M（2024）；2026 寻 \$4B+ 估值。
- **Baichuan** / 百川：医疗 / 企业 vertical 转向。
- **01.AI**（零一万物）：李开复主导，已大幅收缩、转向应用层。
- **StepFun** 阶跃星辰：多模态强项。

3. 应用 / **vertical AI**

- 海外赚钱头部：Talkie (Minimax)、Trip.com AI、SHEIN 个性化引擎。
- 国内：豆包、Kimi、夸克、智谱清言、即梦 (字节图像)、可灵 (快手视频)、海螺 (Minimax)。

投资格局特征

- **GPU** 是硬约束：H20 出口限制 + 国产昇腾 / 寒武纪追赶中 (仍差 1-2 代)。
- 资金来源：阿里、腾讯、字节、米哈游、小米这些产业巨头是主要 LP；传统美元 VC 退场 (高瓴、红杉中国分立)。
- 变现现实：To C 流量起来快但付费率低；To B 项目制为主、续费低于美国。
- **DeepSeek** 的全球地缘意义：把中国 AI 拉回世界叙事中央，但商业上反而稀释了中国「闭源派」(豆包、Kimi) 的护城河。
- 晚点 **LatePost / 36Kr** / 极客公园报道反复揭示：六小龙的「做模型」叙事正在让位「做应用」「做 agent」叙事。

关键中国可投赛道

1. 基础设施替代：寒武纪、海光、华为昇腾生态、HBM 国产替代 (长鑫、长江存储)
2. **vertical AI**：跨境电商 SaaS + AI、医疗影像、金融合规、教育 (多邻国式)
3. **AI 硬件 + 机器人**：宇树 (Unitree)、智元 (Agibot)、银河通用、跨维智能
4. 应用出海：Talkie 模式、AI 视频生成 (可灵 / 即梦海外版)

泡沫论 vs 价值论

泡沫论 (**Bear case**)

David Cahn (Sequoia)：「**\$200B → \$600B 缺口**」

- 计算公式：Nvidia 年化营收 × 2 (数据中心总成本约为 GPU 的 2 倍) = AI 必须创造的年终端价值。
- 2024 年 6 月更新：缺口从 \$125B 跳到 \$500B (OpenAI 占大头但仍杯水车薪)。
- 2026 年视角：OpenAI/Anthropic 营收已从论文写作时的 \$4B 跑到 \$55B+，缺口缩小但仍未消除。

Jim Covello (Goldman Sachs) : 「Too Much Spend, Too Little Benefit」

- 2024 年 6 月报告：未来几年 AI 将花费 \$1T+，但回报远不足以匹配。
- 2026 年立场：Covello 认为只有更确信——「FOMO 比股价表现更强地驱动 hyperscaler 决策」。
- 关键论点：「用极昂贵的技术取代低工资工作，是历次技术换代的反向操作」。

Ed Zitron (Where's Your Ed At) : 「价值幻觉」

- 「一个 \$50B 营收的行业假装自己是 \$1T 的行业」。
- OpenAI 2025 上半年 burn \$9.7B；预计 2029 累计烧 \$115B。
- 数据中心建设落后：宣称的 114 GW 中只有 15.2 GW 真正在建。

MIT / Acemoglu (学院派)

- 经济学家 Daron Acemoglu 估算未来 10 年 AI 对全要素生产率贡献只有 0.06% / 年——远低于乐观派的 1-3% 估计。
- 大量工作被 AI 替代但非高生产力——回报溢出不大。

价值论 (Bull case)**a16z (Andreessen Horowitz)**

- AI 是「比互联网更大的平台 shift」；应用层和工具层会出现千亿级公司。
- Top 100 Consumer Apps 报告显示用户使用每半年扩张一次量级。

Sequoia (Sonya Huang / Pat Grady) 的 Act II / Act o1 / Act IV

- 从 Act II 的「end-to-end 解决人类问题」到 Act o1「推理时代」到 2026「This is AGI」——叙事不断升级。
- 内部矛盾：Cahn 在算账，Huang/Grady 在押 Cursor、Harvey、Glean 等 portfolio 公司——这两种立场是同一家 VC 在做对冲。

Brad Gerstner (Altimeter)

- 「AI 是 supercycle，不是 bubble」；hyperscaler capex 2025 \$500B、2026 ~\$700B 已锁定。
- 押 Nvidia + SK Hynix + CoreWeave + Bloom Energy + Google + Meta。

Foundation Capital : 「\$4.6T opportunity」

- 把 Cahn 的 \$600B 视为传统 IT 替代规模，反算 AI 重塑 SaaS / 服务业的潜在 TAM。

Reid Hoffman / Vinod Khosla 等

- Khosla : 5 年内 AI 替代 80% 经济价值工作，未来 1B 营收公司只需 10 人。
- 资本回报周期会以 10-20 年看，不应用 SaaS 的 2-3 年视角衡量。

我的综合判断

双方都对，时间尺度不同：

- 1-2 年内：基础设施估值有可能调整 30-50%（一次「AI Q4 2026 / Q1 2027 调整」概率不低）。
- 3-5 年：头部模型 + 应用赢家整合，真实生产力红利兑现 20-30%。
- 7-10 年：AI 从 Cahn 的 \$600B 缺口跑到 \$4T+ 经济级影响。

短期估值过热是真的，长期价值兑现也是真的。投资人最危险的态度是把两个尺度搞混。

不同立场和争议（核心 5+ 条）

1. **a16z (Marc Andreessen / Sarah Wang)**：应用层会赢，wrappers 是真公司，分发与体验决定胜负。立场：超级乐观应用派。
2. **Ben Thompson (Stratechery)**：模型成本下降利好应用，但模型公司同时下沉做应用反而能拿到整合利润。Aggregation 让位 Integration——精彩的中间立场。
3. **Vinod Khosla (Khosla Ventures)**：垂直 AI 模型 + 应用一体化是王道；现有大公司未来 10 年大规模消亡。立场：极端激进派。
4. **Cal Newport / Daron Acemoglu**：AI 投资过度，生产力红利被夸大，长期 TFP 贡献 < 0.1%/年。立场：学院怀疑派。
5. **David Cahn (Sequoia) vs Jim Covello (Goldman) vs Ed Zitron**：从内部 VC 算账派、卖方研究怀疑派、媒体批评派三个角度的同向论点——共同点：终端价值跑不赢 capex。
6. **DeepSeek / 开源派**：闭源模型护城河被严重高估，token 价格会持续指数级下跌，未来真正的护城河在分发与数据。
7. **Aaron Levie (Box)**：AI agent 不取代 SaaS 而与 SaaS 共生；token 价格 2026 趋近于零；per-seat 必须被重新发明。立场：温和实用派。
8. **Brad Gerstner / Bill Gurley**：基础设施 supercycle，「trade of the decade」是 picks-and-shovels。
9. **Sonya Huang / Pat Grady**：Act II → Act o1 → 2026 AGI；坚定相信 reasoning + agent 是新台阶，但内部 Cahn 在写缺口报告——两种立场并存。

前瞻假设（5 条可验证）

1. **【芯片格局】**到 2027 Q4，**Nvidia** 数据中心市占从 92% 降到 75% 以下，但绝对营收仍 > **\$300B**——以 hyperscaler ASIC 出货比例与 AMD MI400/450 ramp 验证。

2. 【模型公司变现】到 2026 年底，**OpenAI** 至少推出广告产品，年化广告营收 **\$5B+**——以是否在 ChatGPT Free 引入 sponsored answer 验证。
 3. 【SaaS 转型】到 2027 **Q2**，至少 30% 的传统 **SaaS** 公司主推 **outcome-based / metered** 定价（不只 **add-on**，而是新合同默认）——以 Salesforce/Workday/HubSpot/Zendesk 财报披露混合定价占比验证。
 4. 【中国格局】到 2026 年底，六小龙中至少 2 家被并购或退出第一线（很可能是 01.AI、Baichuan、StepFun 中至少一家）——以一级市场新一轮融资是否完成验证。
 5. 【**vertical AI** 突破】到 2027 年底，至少出现 1 家 **ARR > \$5B** 的 **vertical AI** 应用公司（非通用 **chatbot**）——大概率是 Cursor、Harvey、Glean 之一，或者尚未出现的医疗 / 金融 **vertical agent**。
-

Mermaid 脑图

思维导图 (Mermaid 源)

```

mindmap
  root((AI 投资))
    价值链分层
      能源/电力
      晶圆代工 TSMC
      HBM 存储
      AI 芯片 Nvidia/AMD/ASIC
      云/GPU 租赁
      基础模型
      Middleware
      应用 vertical AI
      服务集成
    护城河
      数据 flywheel
      workflow lock-in
      distribution
      brand/trust
      合规监管
      vertical 一体化
      网络效应
      cost 效率
    定价革命
      per-seat 之死
      outcome-based
      per-action
      token-metered
      success fee
    巨头 vs 新势力
      Google 被低估
      MSFT 稳但贵
      Meta 反弹
      Salesforce 被颠覆
      Adobe 中危
      Atlassian 危
    模型公司
      OpenAI 25B+ ARR
      Anthropic 30B ARR
      xAI 叙事溢价
      DeepSeek 价格屠夫
      Meta Llama 防御
    中国格局
      大厂 阿里字节腾讯
      六小龙分化
      vertical 出海
      硬件替代 寒武纪昇腾
    泡沫争论
      Cahn 600B 缺口
      Covello 太多花费
      Zitron 价值幻觉
      Gerstner supercycle
      Khosla 80% 替代
  
```

完整图形渲染请查看 [HTML 版本](#)。

来源库 (25+ 条)

VC / 行业报告

1. Sequoia – AI's \$600B Question (David Cahn, 2024-06) [<https://sequoiacap.com/article/ais-600b-question/>]
2. Sequoia – Generative AI's Act Two (Sonya Huang, Pat Grady) [<https://sequoiacap.com/article/generative-ai-act-two/>]
3. Sequoia – Generative AI's Act o1: Reasoning Era [<https://sequoiacap.com/article/generative-ais-act-o1/>]
4. Sequoia AI Ascent 2024 Conference [<https://www.sequoiacap.com/article/ai-ascent-2024/>]
5. Sequoia AI Ascent 2025 Conference [<https://sequoiacap.com/article/ai-ascent-2025/>]
6. a16z – Top 100 Gen AI Consumer Apps (6th Edition, 2026) [<https://a16z.com/100-gen-ai-apps-6/>]
7. a16z – State of Consumer AI 2025 [<https://a16z.com/state-of-consumer-ai-2025-product-hits-misses-and-whats-next/>]
8. Bessemer – State of AI 2025 [<https://www.bvp.com/atlas/the-state-of-ai-2025>]
9. Bessemer – Cloud 100 Benchmarks 2025 [<https://www.bvp.com/atlas/the-cloud-100-benchmarks-report>]
10. Foundation Capital – \$4.6T Opportunity Reply to Cahn [<https://foundationcapital.com/the-ai-hype-600b-question-or-4-6t-opportunity/>]

模型公司财务

1. SaaStr – OpenAI Crosses \$12B ARR [<https://www.saastr.com/openai-crosses-12-billion-arr-the-3-year-sprint-that-redefined-whats-possible-in-scaling-software/>]
2. OpenAI – \$122B Funding (Accelerate Next Phase) [<https://openai.com/index/accelerating-the-next-phase-ai/>]
3. SaaStr – Anthropic \$14B ARR (14 Months from \$1B) [<https://www.saastr.com/anthropic-just-hit-14-billion-in-arr-up-from-1-billion-just-14-months-ago/>]
4. VentureBeat – Anthropic \$30B Run Rate, 80x Growth [<https://venturebeat.com/technology/anthropic-says-it-hit-a-30-billion-revenue-run-rate-after-crazy-80x-growth>]
5. Sacra – OpenAI Revenue & Funding Profile [<https://sacra.com/c/openai/>]
6. Sacra – Anthropic Revenue & Funding [<https://sacra.com/c/anthropic/>]
7. Sacra – Perplexity Revenue & Funding [<https://sacra.com/c/perplexity/>]

8. **TechCrunch – Cursor Anysphere \$9.9B Valuation, \$500M ARR** [<https://techcrunch.com/2025/06/05/cursors-anysphere-nabs-9-9b-valuation-soars-past-500m-arr/>]
9. **Cursor – Series D \$29.3B Valuation** [<https://cursor.com/blog/series-d>]
10. **Harvey – Raises at \$11B Valuation** [<https://www.harvey.ai/blog/harvey-raises-at-dollar11-billion-valuation-to-scale-agents-across-law-firms-and-enterprises>]
11. **Glean – \$200M ARR, Doubled in 9 Months** [<https://www.glean.com/press/glean-surpasses-200m-in-arr-for-enterprise-ai-doubling-revenue-in-nine-months>]

Stratechery / 思想领袖

1. **Stratechery – Checking In on AI and the Big Five (2025)** [<https://stratechery.com/2025/checking-in-on-ai-and-the-big-five/>]
2. **Stratechery – AI Integration and Modularization** [<https://stratechery.com/2024/ai-integration-and-modularization/>]
3. **Stratechery – OpenAI, Microsoft and the State of AI** [<https://stratechery.com/2025/openai-microsoft-and-the-state-of-ai/>]
4. **Stratechery – Agents Over Bubbles (2026)** [<https://stratechery.com/2026/agents-over-bubbles/>]
5. **TechCrunch – Box CEO Aaron Levie on AI & Enterprise SaaS** [<https://techcrunch.com/2025/10/29/box-ceo-aaron-levie-on-how-ai-is-changing-the-enterprise-saas-landscape/>]
6. **Khosla Ventures – Vinod Khosla Thought Provoking** [<https://www.khoslaventures.com/entrepreneurs/thought-provoking>]
7. **TechCrunch – Vinod Khosla at Disrupt 2025** [<https://techcrunch.com/2025/09/23/vinod-khosla-on-ai-moonshots-and-building-enduring-startups-all-at-techcrunch-disrupt-2025/>]

泡沫论 / 反方

1. **Goldman Sachs – Gen AI: Too Much Spend, Too Little Benefit?** [https://www.goldmansachs.com/images/migrated/insights/pages/gs-research/gen-ai--too-much-spend,-too-little-benefit-/TOM_AI%202.0_ForRedaction.pdf]
2. **Fortune – Goldman's Covello Says FOMO Driving AI Boom** [<https://fortune.com/2026/05/06/is-ai-a-bubble-goldman-sachs-skeptics-overhyped/>]
3. **Where's Your Ed At – OpenAI's Money Going** [<https://www.wheresyoured.at/where-is-openais-money-going/>]
4. **Computerworld – OpenAI to Burn Through \$115B by 2029**

硬件 / 基础设施

1. **Nvidia – Q4 FY2026 Financial Results (\$68.1B Q4, \$215.9B FY)** [<https://nvidianews.nvidia.com/news/nvidia-announces-financial-results-for-fourth-quarter-and-fiscal-2026>]
2. **ServeTheHome – Nvidia Q4 FY2026 Earnings Detail** [<https://www.servethehome.com/nvidia-reports-q4-fy2026-earnings-data-center-and-proviz-drive-revenue-records/>]
3. **The Motley Fool – Cerebras and Nvidia Rivals Make Moves** [<https://www.fool.com/investing/2026/04/21/cerebras-and-other-nvidia-rivals-just-made-key-mov/>]
4. **Tom's Hardware – DeepSeek's 50,000 GPUs, \$1.6B Buildout** [<https://www.tomshardware.com/tech-industry/artificial-intelligence/deepseek-might-not-be-as-disruptive-as-claimed-firm-reportedly-has-50-000-nvidia-gpus-and-spent-usd1-6-billion-on-buildouts>]
5. **CapitalAI Daily – Altimeter Top Picks, \$500B AI CapEx 2026** [<https://www.capitalaidaily.com/altimeters-brad-gerstner-reveals-google-nvidia-and-six-other-stocks-as-firms-top-picks-sees-ai-capex-jumping-to-500000000000-in-2026/>]

定价模式

1. **Salesforce – Flexible Agentforce Pricing News** [<https://www.salesforce.com/news/press-releases/2025/05/15/agentforce-flexible-pricing-news/>]
2. **SaaStr – Salesforce Now Has 3+ Pricing Models for Agentforce** [<https://www.saastr.com/salesforce-now-has-3-pricing-models-for-agentforce-and-maybe-right-now-thats-the-way-to-do-it/>]
3. **Microsoft Q1 2026 Earnings, Copilot Adoption** [<https://www.heygotrade.com/en/blog/microsoft-q1-2026-earnings-reaction/>]

中国 AI

1. **MIT Technology Review – Four Chinese AI Startups Beyond DeepSeek** [<https://www.technologyreview.com/2025/02/04/1110942/four-chinese-ai-startups-deepseek/>]
2. **SCMP – Beyond DeepSeek: Moonshot, MiniMax New Frontier Labs** [<https://www.scmp.com/tech/big-tech/article/3334602/beyond-deepseek-moonshot-and-minimax-step-chinas-new-frontier-ai-labs>]
3. **MIT Technology Review – China's Open-Source Bet (2026)** [<https://www.technologyreview.com/2026/04/21/1135658/china-open-source-models-ai-artificial-intelligence/>]
4. **Interconnects – Ranking Chinese Open Model Builders** [<https://www.interconnects.ai/p/chinas-top-19-open-model-labs>]

Wrapper 辩论 / vertical AI

1. **VC Cafe – Are AI Wrappers Investable?** [<https://www.vccafe.com/2025/05/14/are-ai-wrappers-investable-the-case-for-and-against/>]

2. **MarkTechPost – It's Okay to Be a Wrapper** [<https://www.marktechpost.com/2025/07/29/its-okay-to-be-just-a-wrapper-why-solution-driven-ai-companies-win/>]