

07 · 基础设施、算力、地缘

视角定位：把 AI 当作一台物理机器来理解。前面的章节看模型、看应用、看资本，但所有这些最终都会落到三件东西上：硅、电、人。本章关心的是 LLM 的"血肉骨骼"——谁制造芯片、谁建数据中心、谁掌握能源、谁拿到出口许可。理解这一层，才能判断 AI 的"上限"和"卡点"到底在哪里。

一句话总览

AI 已经从"软件革命"硬转向"工业革命"——一个 1GW 的 AI 数据中心相当于一座中型核电站、一座小型城市，单次训练的电力成本和资本支出已逼近半导体 fab 的尺度；算力供给侧的瓶颈正从逻辑芯片移向 **HBM**、再移向 **ASML EUV** 设备和电网变压器，而中美脱钩把这条供应链强行劈成了两个互不兼容的体系。

关键句提纲（10 条）

1. 训练算力 4-5x/年增长（Epoch AI），自 2010 年起持续 14 年，2025 年首批模型跨过 1e26 FLOP（Grok-3 是第一个），预计 2030 年单次训练运行需 **4-16 GW** 电力。
2. 数据中心尺度跃迁：从 100MW（2022 年）→ 1GW（2024 xAI Colossus、Anthropic New Carlisle）→ 5GW（2026 Anthropic-AWS、Stargate Abilene）→ 10-100GW（2027-2030 路线图）。
3. 训练成本曲线：GPT-4 ~\$100M（2023）→ DeepSeek V3 名义 \$5.5M（2024，但实际累计 capex 50K Hopper GPUs）→ GPT-5 单次训练 \$500M+（2025）→ Stargate 4 年 \$500B 总投入。
4. 推理成本跌 99%，但 **reasoning** 模型让单次"任务"成本反而上升：GPT-4 → GPT-4o 输入 token 价格降 92%，GPT-3.5 等价模型 token 价格 22 个月跌 280x；但 o1/o3 一次 ARC-AGI 推理消耗的 token 是 GPT-4o 的 60 万倍。
5. **Nvidia** 护城河 = **CUDA × NVLink × HBM** 配额 × 系统级集成（**GB200 NVL72** 把 72 颗 **Blackwell** 当一颗 **GPU** 跑）。Blackwell 卖到 2026 年中已售罄，订单 360 万片，Huang 把 2027 年前累计需求从 \$500B 上调到 \$1T。
6. 挑战者三阵营：(a) 大厂自研 ASIC（Google TPU v7 Ironwood、AWS Trainium 3、Meta MTIA、Microsoft Maia）；(b) 开放生态（AMD MI355X 已在推理上对标 B200，MI400 2026

出货) ; (c) 推理专用 ASIC (Groq LPU、Cerebras WSE-3、Etched Sohu Transformer-only ASIC) 。

7. 电力成"新铀矿"：美国数据中心耗电 2030 占总用电 9-12% (vs 2023 的 4%)，微软 20 年 \$16B 重启 Three Mile Island 833MW 核电、Google 与 Kairos 签 SMR、Meta 转向天然气 + 地热，Texas ERCOT 已成全美 AI 选址第一热区。
8. 数据墙 2026-2028 触顶：Epoch 估高质量公开文本最早 2026 用尽，合成数据 (DeepSeek R1 自蒸馏、Microsoft SynthLLM) + 视频/多模态 + RLHF 互动数据成为下一波"燃料"。
9. 中美芯片脱钩三轮升级：2022.10 (首版禁令) → 2023.10 (封 H800/A800) → 2024.10/2025.05 (封 H20、AI Diffusion Rule、Huawei Ascend 全球禁运)；TSMC 2nm 留在台湾、Arizona 仍只到 4nm/3nm；华为 910C 性能逼近 H100 但被 HBM 卡到 250-300K 片/年。
10. 主权 AI 兴起：UAE G42 在印度部署 8 exaflop (2025)、法国与 UAE 签 1GW 联合数据中心 (\$30-50B)、沙特 PIF 通过 Sanabil 投 Mistral，欧洲—中东—印度形成"非中非美"第三极。

算力增长曲线 · 训练 vs 推理 capex 拆分

Epoch AI 的核心数据 (必读)

- 训练算力增速：自 2010 至今 4-5×/年；前沿 LLM 自 2020 起 5×/年，相当于 5.2 个月翻一倍。这条线在 2018 年后略放缓 (约 4.2×/年)，但仍未明显出现 plateau。
- 首批 **1e26 FLOP** 模型：xAI Grok-3 (2025.02)。Epoch 预测 2027 年起会有 ~30 个模型跨过该门槛，2030 年 200+。开源模型预计 2026 年内突破 1e26 (DeepSeek V4、Qwen3、Llama 4 候选)。
- 算力分解：训练 FLOPs 增长 = 集群更大 × 训练时间更长 × 硬件单卡更强；近三年集群规模增长贡献最大。

训练 vs 推理 capex 的反转

到 2025 年下半年，全行业推理 capex 首次超过训练 capex，这是过去 15 年训练主导格局的根本性反转。原因：

1. 模型从"少而精"转向"多而广"，B 端部署量级跳一个数量级；
2. **reasoning** 模型 让单次推理消耗 50-100 倍 token (详见下节)；
3. agent loop (autoGPT、Devin、Computer Use) 让一次"任务"调用模型几十到几百次。

Dylan Patel 在 Dwarkesh 访谈 (2026.03) 里直言："你应该把任何号称要做 'training cluster' 的项目重新理解为 inference cluster——因为生命周期里 80% 的 GPU 时长都会被 inference 占。"

"AI factory" 概念

Jensen Huang 2025 GTC 把数据中心重新定义为 **AI factory**：原料 = 电 + 数据，产物 = token，单位经济用 **token throughput / Joule** 衡量。NVIDIA 的 DSX 平台把整栋楼当一颗"超级芯片"做协同设计，包含液冷、PSU、网络、供电——这是从"卖卡"升级到"卖发电厂"的商业模型。

训练成本曲线 · 从 \$100M 到 \$500B

时点	模型	单次训练	集群规模	备注
2023.03	GPT-4	~\$100M	~25K A100	Altman 公开口径
2024.04	Llama-3 405B	~\$60M	16K H100	Meta 公开
2024.12	DeepSeek V3	名义 \$5.5 M	2048 H800 (marginal)	实际背后 ~50K Hopper GPU 集群
2025.01	DeepSeek R1	名义 \$5-6M (追加 RL)	同上	"训练成本神话"主角
2025	GPT-5	~\$500M (多次 run)	多次失败重训	Reuters / Information 报道
2026	Anthropic-AWS Rainier	\$35B+ (基建)	1M+ Trainium2/3	1.1GW，史上最大 AI 集群
2025-29	Stargate 全计划	\$500B 4 年	7GW 已规划	OpenAI + Oracle + SoftBank + MGX

DeepSeek 启示与争议：

- 神话派：\$5.5M 把 OpenAI 的 100× 训练成本打回原形，算法 + 工程效率（**FP8**、**MoE** 路由、**custom NCCL**）可以绕过算力霸权。
- 拆穿派（SemiAnalysis）：这只是 marginal GPU 租金，DeepSeek 后面其实是 ~50K Hopper 的累计 capex（远高于 \$500M），加上 200+ 顶级研究员。
- 真实读法：DeepSeek 真正贡献是把"前沿模型再训练成本"拉低到中等基金可承受的范围，但首次开拓的成本（数据工程、架构搜索、失败 run）仍以亿美元计。

推理革命 · reasoning 模型让 token 暴涨

核心冲击

OpenAI o1、o3、DeepSeek R1、Google Gemini 2.5 Thinking、Anthropic 拓展思考模式，全部走"长思维链 + test-time scaling"路线。后果：

- 单次请求 token 消耗 5-100× 于传统模型。一个简单 coding 题，DeepSeek R1 生成 4000 个 thinking token，GPT-4o 仅 150 token——26× 差距。
- ARC-AGI 上 o3 的 high-efficiency 模式相对 GPT-4o 等价输出成本上涨 600,000×（极端样本）。即使 OpenAI 2025.06 把 o3 价格从 \$10/\$40 砍到 \$2/\$8 per million tokens（80% 降价），同等任务仍贵 GPT-4o 5-10×。
- **KV cache** 内存爆炸：30,000 token 的 reasoning chain 单次产生 ~2GB KV cache，相当于占据 50 个标准 600-token 请求的内存。

长上下文 + agent loop 的算力倍增

- 长上下文：Gemini 2 Pro 200 万 token、Claude 200K、GPT-5 1M+。注意力复杂度 $O(n^2)$ ，512K 上下文相当于 256× 传统 4K 上下文的算力。
- **Agent loop**：一个浏览器 agent 完成"查机票 + 订酒店 + 写报告"，模型被调用 50-200 次；coding agent（Claude Code、Cursor、Devin）单次任务 100-500 次调用很常见。

推理成本优化方向（必读清单）

1. **MoE (Mixture of Experts)**：DeepSeek V3 / Mixtral / Llama4 已普及。激活参数仅 5-15% 总参数，每 token FLOPs 大幅下降，但 KV cache 和路由开销引入新瓶颈。
2. **Speculative decoding**：小 draft 模型并行生成多 token，大模型一次性 verify，2-3× 吞吐提升。
3. **Caching** (KV cache reuse、prompt caching)：Anthropic、OpenAI、Google 都已商用，长 prompt 重复场景成本降 90%。
4. **Distillation**：把 R1/o1 的 reasoning 能力蒸馏到 7B-30B 小模型（DeepSeek-R1-Distill 系列、Qwen QwQ）。
5. 专用 **ASIC**：Etched Sohu 把 Transformer "刻死"在硅上，Llama 70B 推理 500K tokens/s，对比 8 卡 H100 的 23K tokens/s ——20× 性价比。

行业判断：未来 18 个月推理 per-token 价格还会再跌 10×，但单任务成本 会因为 reasoning + agent 而上升 2-5×。也就是说：单位 **token** 极便宜，单位智能极昂贵。

推理基建对硬件的反向需求重塑

reasoning 模型的崛起把硬件需求曲线从"稠密大算力"转向"高内存带宽 + 低延迟单流"。具体含义：

- **HBM** 容量与带宽比 FLOPS 更关键——AMD MI355X 用 288GB HBM3e 在长 reasoning 场景上可以与 192GB 的 B200 抗衡，正是因为 KV cache 整体能装得下、不需要频繁 swap。
- **batch size 1** 优化比"大 batch 高吞吐"更重要：用户等待 thinking token 时，无法等到聚一个大 batch 再 decode。Groq、Cerebras、Etched 押的就是这个方向。
- **rack-level** 互联：72 卡 NVL72 把 KV cache 跨卡共享，本质上让 reasoning 的"长思维链"可以驻留在更大的"逻辑 GPU"内存里，这是 Nvidia 当前最锋利的差异化武器。
- 预算分配重塑：Anthropic 内部把推理 capex 比例从 2023 的 30% 调到 2025 的 60%+，OpenAI 的 Stargate 早期规划已明确写入"50% 推理用途"。

硬件格局 · 五个梯队

第一梯队：Nvidia（市占 ~85% AI 加速器）

- **CUDA 17** 年沉淀：上千万开发者、数百万行优化 kernel、PyTorch / Triton / cuDNN / TensorRT 层层深入。
- **NVLink + NVSwitch**：GB200 NVL72 把 72 颗 GPU 通过 NVLink 5（1.8 TB/s 双向）拧成一颗"巨型 GPU"，13.5 TB HBM3e 共享内存。这是目前全行业唯一规模化 rack-level 解决方案。
- **Blackwell** 现状（2026.05）：B200 售罄至 2026 年中，订单 backlog 360 万片；B200 单卡 20 PetaFLOPS，万亿参数推理较 H100 提速 30x。
- **Vera Rubin** 路线（2026 年 H2）：Rubin GPU + Vera CPU 一体化，Huang 在 GTC 2025 把 2027 年前累计需求展望从 \$500B 调到 \$1T。

第二梯队：大厂自研 ASIC

厂商	当前主力	状态
Google	TPU v7 Ironwood (2025.04 发布)	9216 卡 cluster 4614 TFLOP/s，用于 Gemini 训练，对外 Cloud TPU
AWS	Trainium 2/3	Project Rainier 50 万颗 Trainium2，Anthropic 锁 5GW、\$100B 10 年
Meta	MTIA v2	内部部署，主要驱动 Llama4 推理 + 推荐
Microsoft	Maia 100 / Cobalt	自用 Azure，推理为主

结论：Google TPU 是技术最成熟的非 Nvidia 生态，AWS Trainium 在性价比上对内 dump 给 Anthropic，但外部生态吸引力仍弱。SemiAnalysis 把 TPU v7 称为"房间里的 900 磅大猩猩"。

第三梯队：AMD

- **MI355X / MI350X** (2025.06 发布)：288GB HBM3e (vs B200 的 192GB)，声称在 DeepSeek、Llama 推理工作负载上比 B200/GB200 快 20-30%、tokens-per-dollar 高 40%。
- **MI400 "Vulkan"** (2026 年 H2)：单卡 10× MI355X，3D 封装 + 300GB scale-out 带宽。
- **ROCm 7**：在 PyTorch / Llama 主流栈上接近 CUDA 可用性；但 SemiAnalysis 实测 H100/H200 训练 benchmark 仍领先——**CUDA moat still alive**。

第四梯队：推理 ASIC 创业军团

- **Groq**：LPU 单卡推理速度极致快 (Llama 70B 750+ tok/s)，但单卡内存太小，成本结构上对长上下文不友好。
- **Cerebras**：Wafer-scale Engine 3，22 cm² 单芯片，可单卡跑 7B-405B；2025 IPO 重启。
- **SambaNova**：可重构 dataflow，介于 GPU 与 ASIC 之间。
- **Etched Sohu**：transformer-only ASIC，2025 出货，500K tok/s (Llama 70B 8 卡)，但只跑 transformer——赌的是 **Transformer** 还会主导 5-10 年。
- **NVIDIA** 反应：2026.01 NVIDIA 投资 Groq 部分股权，把潜在威胁纳入生态。

第五梯队：中国"自循环"

厂商	主力芯片	性能对标	瓶颈
华为	Ascend 910C / 910D / 920	接近 H100 (整包双 die)	HBM 受限，2026 全年最多 25-30 万片
寒武纪	思元 590	A100 级	软件生态
海光	DCU K100	A100/MI200 级	制造受限
壁仞 / 摩尔线程	BR100 / MTT S4000	A100 级	受美国 entity list 影响

关键事实：华为 2024-2025 通过 SMIC + 部分 TSMC 流片（违规绕道，被美国 BIS 公开点名），积累了 ~290 万颗 Ascend die；但 **HBM** 是真瓶颈——CXMT 2026 年最多产 200 万 stack HBM，仅够 25-30 万颗 Ascend 910C；这意味着中国 2026 年自有先进 **AI** 加速器供给上限大约相当于 5 万张 **H100** 的训练等效，远低于美国头部单家 hyperscaler。

数据中心 & 电力 · 真正的瓶颈

尺度跳跃

时期	单数据中心规模	代表
2020-2022	50-100 MW	传统 hyperscaler
2023-2024	100-300 MW	xAI Colossus phase 1 (250MW)
2025	500MW-1.1 GW	Anthropic-AWS New Carlisle (1.1GW)、Stargate Abilene (1.2GW phase)
2026-2027 (规划)	1-5 GW	Stargate 全网 7GW、Anthropic 5GW、Meta Hyperion 5GW
2030 (前瞻)	10-100 GW	Aschenbrenner "trillion-dollar cluster"

对比：2023 年全美数据中心总耗电 49GW；2026 全球 96GW，其中 AI 占 40GW。
Aschenbrenner 估 2030 单个训练 cluster 用电 100GW = 美国总用电 20%。

电力供给的四条路径

1. 核电复苏：Microsoft × Constellation 2024.09 签 20 年 \$16B，重启 Three Mile Island Unit 1 (833MW，目标 2028 上电)；Amazon 收购 Talen 核电资产；Google × Kairos 签 SMR 500MW (2030+)；Oracle 公开规划自建 SMR 配套 Stargate。
2. 天然气：Meta、xAI 在 Texas / Louisiana 直接 behind-the-meter 天然气发电厂（绕开电网审批 18-24 个月延迟）。
3. 地热：Sam Altman 个人投资 Fervo / Helion，2025 起小规模上线。
4. 电网升级：变压器 lead time 已从 2022 年 30 周拉到 2025 年的 120-200 周，是新数据中心最确定的瓶颈。

美国电网瓶颈分布

- **ERCOT**（德州）：受益于轻监管、有自主电网、土地便宜，成 AI 选址第一热区（Stargate Abilene、xAI Memphis 实际通过 Tesla MegaPack 缓冲电网波动）。
- **PJM**（中大西洋）：北弗吉尼亚 Loudoun County 已是全球最大数据中心集群，但电网容量耗尽；2024 PJM 容量拍卖价格暴涨 800%，直接传导到电费。
- **Pacific Northwest**：水电 + 寒冷气候本是天然 AI 选址，但近年干旱使风险上升。

散热与 PUE 革命

- 1GW AI 数据中心的余热相当于一座小钢厂，传统风冷彻底失效，直接液冷 (**Direct-to-Chip**) + 浸没式冷却成为新标配；GB200 NVL72 必须液冷，已不再提供风冷选项。
- PUE (Power Usage Effectiveness) 从传统 1.5-1.6 的目标拉到 1.1-1.2；超大数据中心运营商把"水"作为新瓶颈——单 GW 数据中心年耗水可达 25-50 亿升。
- 冷却选址博弈：北欧 (瑞典 Luleå、挪威 Stavanger)、爱尔兰、芬兰因低温优势再度受关注；但电网容量 + 主权法规正在反向限制——2024 爱尔兰已暂停审批新数据中心。

资本支出节奏与现金流压力

- Microsoft / Google / Amazon / Meta 四家 2025 合计 capex ~\$370B，2026 预计 \$500B+，首次 集体超过经营现金流 100%。
- Goldman 测算 hyperscaler 平均 GPU 折旧周期 4-6 年，但实际性能上的"经济寿命"只有 2-3 年 (Hopper 在 Blackwell 出货后 inference 性价比下降 60%+)。
- 行业隐藏债务：OpenAI / Anthropic 通过 hyperscaler 间接绑定的"承诺采购"已超 \$400B，本质上把模型公司的偿债能力与 hyperscaler 资产负债表绑定 (Anthropic-AWS \$100B 10 年合约 + OpenAI 各种"compute commitments")。

数据墙 · 公开互联网真的耗尽了？

Epoch AI 的核心结论

- 全球高质量公开文本约 300 trillion tokens (2024 估算)。
- 若按 5× overtraining，2027 用尽；按 100× overtraining，2025 用尽；按 Chinchilla optimal，2032-2034。
- LeCun 等人持反对意见：人类生成新数据的速度不慢，关键是"高质量"如何定义。

替代路径

1. 合成数据：DeepSeek R1 用 reasoning chain 自蒸馏 → 800K 高质量 SFT 样本；Microsoft Phi 系列证明高质量合成数据 + 小模型也能达到接近前沿性能；Microsoft SynthLLM 实验表明合成数据仍服从 **scaling law**。
2. 多模态扩展：YouTube 一个平台年新增视频 token 远超全互联网历史文本量。视频—音频—3D—具身数据是下一块"未开采矿"。
3. 互动数据：ChatGPT/Claude/Gemini 用户日均生成 100+亿 token 真实交互，是闭源生态最大的隐藏护城河 (OpenAI 拥有 8 亿 ChatGPT WAU 的对话数据)。

4. **Agent self-play**：在沙箱环境中让 agent 自我交互生成新轨迹（Voyager、SIMA、AlphaProof 已证明部分领域可行）。

Anthropic 内部研究人员 Aug 2025 在播客中表示："对前沿实验室来说，公开网络数据只是基线，我们 60-80% 的训练价值已经来自合成 + 互动数据。"

数据墙的反直觉含义

第一性原理上看，"数据耗尽"这件事的真正影响不是 **capex** 减少，而是 capex 结构再分配：

- 1. 数据采购 + 标注 成为继 GPU 之后的第二大成本项；OpenAI、Anthropic、xAI 在 2024-2025 累计花费超 \$20B 用于数据交易（Reddit、Stack Overflow、新闻出版社）。
- 2. **RLHF / RLAIF labor** 市场：Scale AI、Surge、Snorkel 等数据公司估值翻倍；高难度领域（医学、法律、coding）专家时薪 \$200-500。
- 3. 计算合成数据本身需要 **GPU**——R1 自蒸馏过程消耗的 inference compute 与训练 compute 同量级，意味着算力需求并没有"省下来"，只是换了用途。

这导致一个推论：如果数据成为强约束，前沿实验室会更需要拥有"用户互动闭环"的产品——这反过来强化了 ChatGPT、Claude.ai、Gemini App 这些 C 端产品的战略价值，而非削弱。

中美地缘博弈 · 三轮升级后的格局

出口管制时间线

日期	事件
2022.10.07	BIS 首版"7nm 以下 AI 芯片禁令"，A100/H100 出口受限
2023.03	Nvidia 推出 H800（NVLink 降至 400GB/s）合规版
2023.10.17	BIS 禁令升级，H800/A800/L40S 全数禁运；引入 TPP（性能 × 互联）阈值
2024.10	"AI Diffusion Rule" 草案，引入"Tier 1/2/3 国家"分层
2025.01	Diffusion Rule 正式发布，主权国家分级
2025.04	Trump 政府禁 H20（Nvidia 第三代合规版）
2025.05	BIS 撤销 Diffusion Rule；同日全球禁用华为 Ascend 910B/C/D （任何人使用即违法）
2025.07-08	部分回退：Nvidia H20 / AMD MI308 重新允许销售中国，但对美政府支付 15% 收入抽成（前所未有）

三方博弈格局

美国阵营：Nvidia + AMD + Intel + 大厂自研芯片 + TSMC（事实上的“美方代工厂”，2nm 留台、Arizona 4nm 已量产）+ ASML（荷兰，最关键节点）+ 三星 / SK Hynix（韩国，HBM）+ 应用材料 / LAM / KLA（设备）。

中国阵营：华为 Ascend + SMIC（先进制程瓶颈，N+2 节点对标 5-7nm）+ CXMT（HBM 自主，2026 仅能产 250-300K Ascend 910C 等量 HBM）+ 中芯/华虹/上海微电子（光刻机国产化，DUV 已能做 28nm，EUV 仍空白）。

第三极（主权 **AI**）：

- **UAE** / 沙特：G42 + ADQ + Mubadala + PIF / Sanabil 投资 Mistral、Anthropic、xAI；G42 在印度部署 8 EFLOP；与法国签 \$30-50B 1GW 联合数据中心。
- 印度：Yotta、Tata、Reliance 自建 GPU 集群；G42 8EFLOP 部署成最大单点。
- 欧盟：Mistral（法国）+ Aleph Alpha（德国）+ EuroHPC（Jupiter 1 EFLOP）；French Stargate 类项目（Iliad + Mistral + UAE）。
- 日韩：Naver HyperCLOVA X、SoftBank（也是 Stargate 主席）；日本 SoftBank-OpenAI Cristal Intelligence 项目。

台积电分散与“硅盾”

- **Arizona**：6 fab 规划（4nm 已量产，3nm 2026，2nm 2028+），由日本贷款、美国《CHIPS Act》\$66B 补贴助力。
- **Kumamoto**（日本）：6nm 已量产，但需求疲软，原计划 2nm 跳跃推迟。
- **Dresden**（德国）：与 NXP / Bosch / Infineon 合资，主攻汽车工业 mature node。
- 核心矛盾：台湾保留 2nm 的政策红线 vs 美国不希望“硅命脉”放在台海冲突火线上。2027-2028 是关键转折点——若 Arizona 2nm 顺利量产，台湾的“硅盾”威慑会显著弱化。

中国“算力闭环”的真实进度

抛开宣传与封锁两端的噪音，2026 年中国 AI 算力的实际状况大致是：

- 逻辑芯片自给率 ~30-40%（按算力等效折合）：华为 Ascend 910C 在 SMIC 的 N+2 节点流片，单卡性能约为 H100 的 60-70%（FP16），但通过双 die 互联接近 H100 整包水平。
- **HBM** 自给率 <15%：CXMT HBM2/2e 良率仍未稳定，HBM3 量产推迟到 2026 H2；中国 AI 加速器 HBM 大头仍依赖三星 / SK Hynix 走灰色渠道（已被美国 BIS 多轮警告）。
- **EUV** 完全空白：上海微电子最先进 DUV 已能做 28nm 双重曝光，但要做 7nm 以下仍需 EUV，这条路至少落后 5-7 年。
- **DeepSeek** 路径：用算法 + 集群效率（FP8、MoE、custom NCCL）把 H800 的限制变成“算法优势”，这条路径在 2025-2026 是中国前沿大模型的主战场。

- 政策抗风险：北京"东数西算"政策指引算力建在西部清洁能源充足处；但电网调度、跨省结算仍是落地难点。

一个被低估的观察：中国的"算力受限"反而催生了全行业最专注的推理优化研究。DeepSeek、Moonshot、智谱、阿里 Qwen 团队在 inference 效率上的论文密度远超美国同行，这是被禁运逼出来的能力。

出口管制的一个反直觉效应

CSIS、Epoch、CSET 多份分析共同指出：出口管制没能阻止中国前沿模型出现，但显著拖慢了规模化部署。

- DeepSeek、Qwen、智谱、字节豆包训练算力总和大约 = 美国一家头部实验室（如 Anthropic）的水平；
- 但中国 inference 部署能力（按累计 token 处理量）大约只有美国的 1/10——因为推理需要海量 GPU 在岗。
- 这意味着：中国正在制造"小规模前沿"，但难以构建大规模 **agent** 经济——这恰恰是出口管制设计者的核心目标。

不同立场和争议

立场 A：Aschenbrenner 派（最 **bullish**）

- 核心论点 ("Situational Awareness", 2024.06)：算力 0.5 OOM/年 + 算法效率 0.5 OOM/年 + "unhobbling" gains, **2027 AGI strikingly plausible**；2030 出现 100GW、\$1T 单 cluster。
- 二年后复盘：Aschenbrenner 的算力路径基本被证实（2026 已有 1M H100-eq cluster），但 AGI 时间线略 over-shoot。

立场 B：Yann LeCun 派（架构怀疑）

- LLMs are a "**dead end**"——他们只是堆叠统计相关性，缺常识、因果、世界模型。
- 2025.11 LeCun 离开 Meta，创办 AMI，融资 \$1B 押注 JEPA / world model。
- 后果：如果 LeCun 是对的，算力 capex 的边际收益会快速衰减——"再加 10× 算力"换不来 10× 智能。

立场 C : **Dylan Patel** 派 (中度乐观, 工程视角)

- AMD 短期内 (2026-2027) 无法撼动 Nvidia, 但 MI400 + ROCm 生态成熟后会侵蚀 25-30% 推理市场。
- 真正的瓶颈不是逻辑芯片, 而是 **HBM / EUV / 电网变压器 / 高压电缆** (2028+ 落到 ASML 单点)。
- DeepSeek 是真厉害, 但不是颠覆性的低成本——西方实验室的 frontier model 训练里 80% 成本是数据 + 探索 + 失败 run, 不是 GPU 时长。

立场 D : "效率派 / **DeepSeek** 启示"

- 少即是多: 算法、稀疏性、量化、distill 把 capex 需求压到 1/10。
- DeepSeek V3 \$5.5M、Llama-3 405B \$60M、Mistral Small 3 都说明前沿能力开始 **commoditize**。
- 含义: 对开源 / 开放权重模型生态有利, 但对 capex 重投入的 hyperscaler 不利。

立场 E : **Goldman Covello / Ed Zitron** (**capex** 泡沫派)

- 2024 Goldman 报告: \$1T+ capex 至今没有匹配的收入, 95% 企业 GenAI pilot 零回报。
- Microsoft / Amazon / Google / Meta 现在 capex > 100% 经营现金流, 史无前例。
- Zitron: Big Tech 2030 前需要 **\$2T** 新增 **AI** 收入才能 cover capex, OpenAI + Anthropic 占 hyperscaler AI capex 75% (循环资本游戏)。
- 反驳: Aschenbrenner / Altman 派认为他们看的是"通用智能"上限和锁定行业基建的长期回报, 而非短期单年 ROI。

立场 F : "能源是真瓶颈"派

- Meta、Microsoft、Google CTO 私下都把电力列为首要约束, 超过芯片。
- 2026-2028 期间电网变压器是单点瓶颈, 无法用钱在 24 个月内突破。
- 后果: AI cluster 的地理分布会发生大迁徙——往德州、爱荷华、北达科他 (核 / 风 / 气资源充足处)。

前瞻假设 (5 条)

1. 2027 年单个训练 **cluster** 突破 5 **GW**, 对应 2-3M H100-eq; 至少出现两个由主权基金 (沙特或 UAE) 牵头的非美主导 cluster。
2. 推理 **capex** 在 2027 占 **AI** 总 **capex 70%+**, agent 经济 (每用户每天 50-500 次模型调用) 成为核心驱动; Etched / Groq / Cerebras 之一被大厂收购或上市达到 \$50B+ 估值。

3. **Nvidia** 市占降至 60-65% (vs 2024 的 90%+) , 不是因为 CUDA 被打破, 而是因为大厂自研 ASIC (TPU、Trainium、MTIA、Maia) 已在内部消化 25-30% 推理需求。
 4. **HBM** 短缺持续到 2027 : SK Hynix + 三星 + Micron + CXMT 的 HBM4/4e 产能扩张被 ASML EUV 工具供给限速; 中国 Ascend 输出实际能力锁定在 30-50 万片/年量级。
 5. 数据墙不会以"耗尽"形式撞墙, 而以"质量陡降 + 合成数据收益递减"形式渐进式显形。前沿实验室未来 24 个月最大优势来自多模态 + 互动 + **agent self-play**而非更多互联网爬取。
-

Mermaid 脑图

思维导图 (Mermaid 源)

```
mindmap
  root((算力 & 地缘))
    训练算力曲线
      4-5x 年增长 (Epoch)
      Grok-3 1e26 FLOP
      2030 10-100 GW cluster
      数据墙 2026-28
    推理革命
      reasoning 50-100x token
      agent loop 50-500x 调用
      MoE / spec-decode / cache
      ASIC: Etched Groq Cerebras
    硬件格局
      Nvidia (CUDA NVLink HBM)
      Blackwell B200 GB200 NVL72
      Vera Rubin 路线
    大厂 ASIC
      Google TPU v7 Ironwood
      AWS Trainium 2/3
      Meta MTIA Microsoft Maia
      AMD MI355X MI400
    推理 ASIC startups
    中国: 华为 寒武纪 海光
    数据中心 & 电力
      100MW 1GW 5GW 100GW
      核电复苏 (TMI Kairos)
      天然气 + 地热 + SMR
      电网变压器瓶颈
      ERCOT vs PJM
    地缘博弈
      美国出口管制三轮
      TSMC 分散 (AZ JP DE)
      华为 Ascend 路径
      HBM 真瓶颈
    主权 AI
      UAE G42 ADQ MGX
      沙特 PIF Sanabil
      欧盟 Mistral Aleph
      印度 Yotta Tata
      法国-UAE $30-50B
    争议
      Aschenbrenner 2027 AGI
      LeCun LLM 死路
      Patel 工程瓶颈
      DeepSeek 效率派
      Goldman 泡沫派
      能源真瓶颈派
```

完整图形渲染请查看 HTML 版本。

来源库

核心媒体 & 分析师 (必读)

1. SemiAnalysis (Dylan Patel) — semianalysis.com / newsletter.semianalysis.com 全行业最深的 chip + datacenter 追踪。
2. Epoch AI — epoch.ai/trends 训练算力数据库，引用最权威。
3. Dwarkesh Patel Podcast — dwarkesh.com 与 Patel、Aschenbrenner、Sutskever、Altman、Amodei 等核心访谈。
4. Stratechery (Ben Thompson) — stratechery.com 关于 chips、CUDA、AI factory 的商业分析。
5. The Information / Reuters / Bloomberg / FT — semi 地缘一手报道。

关键文章 / 报告

1. Epoch, "Training compute of frontier AI models grows by 4-5x per year" — <https://epoch.ai/blog/training-compute-of-frontier-ai-models-grows-by-4-5x-per-year>
2. Epoch, "How much power will frontier AI training demand in 2030?" — <https://epoch.ai/blog/power-demands-of-frontier-ai-training>
3. Aschenbrenner, "Situational Awareness: The Decade Ahead" (2024.06) — <https://situational-awareness.ai/>
4. Dwarkesh × Dylan Patel, "Deep Dive on the 3 Big Bottlenecks to Scaling AI Compute" (2026.03) — <https://www.dwarkesh.com/p/dylan-patel>
5. SemiAnalysis, "MI300X vs H100 vs H200 Benchmark Part 1: Training - CUDA Moat Still Alive" — <https://newsletter.semianalysis.com/p/mi300x-vs-h100-vs-h200-benchmark-part-1-training>
6. SemiAnalysis, "Huawei Ascend Production Ramp: Die Banks, TSMC Continued Production, HBM is The Bottleneck" — <https://newsletter.semianalysis.com/p/huawei-ascend-production-ramp>
7. SemiAnalysis, "AI Datacenter Energy Dilemma - Race for AI Datacenter Space" — <https://newsletter.semianalysis.com/p/ai-datacenter-energy-dilemma-race>
8. SemiAnalysis, "Google TPuv7: The 900lb Gorilla In the Room" — <https://newsletter.semianalysis.com/p/tpuv7-google-takes-a-swing-at-the>
9. Goldman Sachs, "GenAI: Too Much Spend, Too Little Benefit?" (2024.06) — Jim Covello 主笔

10. Ed Zitron, "Big Tech Needs \$2 Trillion In AI Revenue By 2030" — <https://www.wheresyoured.at/big-tech-2tr/>
11. CSIS / CSET, "Pushing the Limits: Huawei's AI Chip Tests U.S. Export Controls" — <https://cset.georgetown.edu/publication/pushing-the-limits-huaweis-ai-chip-tests-u-s-export-controls/>
12. CRS, "U.S. Export Controls and China: Advanced Semiconductors" (Aug 2025) — <https://www.congress.gov/crs-product/R48642>
13. Stanford FSI, "Taking Stock of the DeepSeek Shock" — <https://cyber.fsi.stanford.edu/publication/taking-stock-deepseek-shock>
14. Lawfare, "What DeepSeek r1 Means—and What It Doesn't" — <https://www.lawfaremedia.org/article/what-deepseek-r1-means-and-what-it-doesn-t>
15. Microsoft Research, "SynthLLM: Breaking the AI 'data wall' with scalable synthetic data" — <https://www.microsoft.com/en-us/research/articles/synthllm-breaking-the-ai-data-wall-with-scalable-synthetic-data/>

公司公告 / 一手

1. OpenAI, "Announcing The Stargate Project" (2025.01) — <https://openai.com/index/announcing-the-stargate-project/>
2. OpenAI, "Five new Stargate sites" (2025.09) — <https://openai.com/index/five-new-stargate-sites/>
3. Anthropic-Amazon, "Anthropic and Amazon expand collaboration for up to 5 GW" — <https://www.anthropic.com/news/anthropic-amazon-compute>
4. NVIDIA, "Blackwell Platform Arrives" — <https://nvidianews.nvidia.com/news/nvidia-blackwell-platform-arrives-to-power-a-new-era-of-computing>
5. NVIDIA GTC 2025 keynote transcript (Jensen Huang) — <https://blogs.nvidia.com/blog/nvidia-keynote-at-gtc-2025-ai-news-live-updates/>
6. xAI, Colossus — <https://x.ai/colossus>
7. AMD, MI350 series — <https://www.amd.com/en/products/accelerators/instinct/mi350.html>
8. Google Cloud, "Trillium TPU" — <https://cloud.google.com/blog/products/compute/introducing-trillium-6th-gen-tpus>
9. Microsoft × Constellation, Three Mile Island PPA (2024.09) — datacenter dynamics 报道
10. DeepSeek-V3 Technical Report (arXiv 2412.19437) — <https://arxiv.org/html/2412.19437v1>

主权 AI

1. G42, "UAE to Deploy 8 Exaflop Supercomputer in India" — <https://www.g42.ai/resources/news/uae-deploy-8-exaflop-supercomputer-india-strengthen-local-sovereign-ai-infrastructure>
2. Middle East Institute, "From Crude to Compute: Building the GCC AI Stack" — <https://www.mei.edu/publications/crude-compute-building-gcc-ai-stack>
3. arXiv 2511.15734, "Sovereign AI: Rethinking Autonomy in the Age of Global Interdependence"

中国视角

1. 晚点 LatePost、财新、远川研究所、硅基立场 — DeepSeek、华为昇腾、HBM 自主化中文一手报道
2. IFP, "The H20 Problem: Inference, Supercomputers, and US Export Control Gaps" — <https://ifp.org/the-h20-problem/>

写作备注：本章侧重物理底层与产业格局，与 03（模型层）、05（资本与商业模式）、08（中国 vs 美国）有显著 overlap，但视角各异。读者可结合 05 看 capex 经济性 / ROI、08 看中美战略博弈、09 看主权 AI 政策维度。