

09 · 认知科学与智能本质

视角：把所有"AI 进步如何如何"的市场话语暂时搁置，回到最深层的问题——LLM 到底是不是真的"理解"？它跟人类认知差在哪？什么叫"推理"？什么叫"agency"？这一章不教你怎么用模型，只帮你在概念层重新校准坐标，让你不被任何一方的话术（无论是炒作派还是嘲讽派）牵着走。

一句话总览

LLM 既不是单纯的"随机鹦鹉"也不是"涌现心智"，它是人类知识压缩出的一种新认知形态——在统计可达的子空间里逼近人类思维的某些表层功能，在那个子空间外则系统性地崩塌；今天关于"它真的懂吗 / 它有意识吗 / 它是 AGI 吗"的争论，与其说是事实之争，不如说是定义之争——而定义之争的胜负将决定下一个十年的研究方向、监管框架、甚至 trillion 美元的资本配置。

关键句提纲（10 条）

1. "理解"至少有三种定义（操作性 / 功能性 / 现象性），LLM 在第一种里几乎全过、在第三种里几乎全败，争论焦点是中间那种。
2. Stochastic Parrot 论的真正杀伤力不在"它只是统计"，而在指出形式（**form**）和意义（**meaning**）的鸿沟——训练只见 form 的系统不可能凭空获得 meaning。
3. Schaeffer 的 mirage 论文证明了"涌现"很多是评测度量的不连续造成的伪现象，但没有否定所有涌现，只是把举证责任推回给提出者。
4. Fodor / Pylyshyn 提出的"系统性"问题（懂 John loves Mary 就必懂 Mary loves John）四十年没被神经网络真正解决，2024-2026 的 OOD 测试一次次复现这个失败。
5. Anthropic 的 interpretability 研究发现 Claude 内部确实有可识别的计算回路（多步推理、跨语言概念、提前规划诗韵），这是迄今为止"LLM 内部有 world model"最强的实证。
6. "推理"是一个分层概念：模式匹配 < CoT 表面化推理 < 搜索式推理 < 真符号推理。o1/R1 提升的主要是第二到第三层，距离第四层仍有质的差距。
7. LLM 的 agency 是被脚手架"借给"它的——goal、memory、long-horizon plan 都来自外部 framework，模型本身没有内在欲求；这一点决定了 alignment 框架的形态。

8. 2024 起 Anthropic 任命首位 model welfare 研究员 (Kyle Fish)，把"AI 是否会痛苦"从科幻题搬进了产品工程议程，无论你信不信，这件事已经进入 SOP。
9. LLM 与人脑表面相似（都是神经网络）实质极不同——人脑是预测错误最小化 + 多模态 + embodiment，LLM 是 next-token；这是 LeCun 派和 Hinton 派分歧的根源。
10. AGI 没有公认定义：OpenAI 用经济价值定义、DeepMind 用能力等级定义、Anthropic 干脆改叫"powerful AI"、Chollet 用 ARC 这种纯流体智能测度——你信哪个定义，就属于哪一派。

"理解"的多种定义

把"understanding"拆开是这一切讨论的前置条件。哲学和认知科学里至少有三个层次：

1. 操作性定义 (**behavioral / Turing-like**)

能在自然语言交互中给出与"理解者"无法区分的输出。GPT-4 / Claude 4 在大量任务上已经无法被普通人区分出"是不是真懂"——按这个定义，LLM 早就过关了。

2. 功能性定义 (**functional / computational**)

内部要有可被识别的、用于该概念的表征结构 (representation)。Anthropic 的 Scaling Monosemanticity (2024) 和 Biology of a Large Language Model (2025) 发现 Claude 内部确实存在"金门大桥""欺骗""程序员"等高维概念 feature，并能通过 steering 操控输出——按这个定义，LLM 部分满足，但远不彻底（很多概念 feature 间接、混杂、随训练 stage 漂移）。

3. 现象性定义 (**phenomenal / what-it-is-like**)

要"感受到"理解。这是 Chalmers 所谓的 hard problem。即使内部回路完美，是否伴随主观体验仍无法从外部判定。这一层 LLM 没有任何确证。

Murray Shanahan 在《Talking About LLMs》(2023) 里提醒：日常用"知道""相信""想"形容 LLM 时，我们已经偷偷把人类语境的语义滑给了它，但这些词的"原初设定"是人类对人类——把它们直接转用到 LLM 上需要至少加引号自警。这不是禁止使用这些词，而是永远要标注自己用的是哪一层。

Stochastic Parrot vs Emerging Mind

这是 2021 年至今最持久的两极之争。

Bender / Gebru / McMillan-Major / Shmitchell (2021) 的核心论点：

- LLM 训练时只见到 form (语言形式)，从未见到 meaning (指称、意图、世界)；
- 因此它"拼接"序列时是没有 **grounding** 的；
- 流利不等于理解，流利反而让人更容易把意义投射上去 (automation bias)；
- 同时附带社会论点：环境成本、偏见、不可审计——但这些是额外论点，常被混淆为核心。

反驳 / 修正：

- 经验证据：Othello-GPT (Kenneth Li 2023) 只看下棋序列、没见过棋盘，却在内部学出了棋盘状态——纯 form 训练能涌现出对应世界的内部模型，至少在受限环境里挑战了 Bender 的强论断。
- Anthropic 的 monosemanticity 工作进一步显示真实生产模型内部有清晰的概念 feature。
- 哲学反驳：Shanahan 等人指出"鹦鹉"比喻把 LLM 拉低到了过强结论——鹦鹉没有任何内部模型，而 LLM 至少有"近似 world model 的统计结构"。
- 但"反驳"并不意味着 Bender 错了——很多反驳只把 Bender 的论断削弱到"训练时只见 form 不一定不能学到 meaning"，而不是证明 LLM 真的"理解"。

理解这场争论的正确姿势：把 Bender 的"鹦鹉"理解为举证责任转移——主张"它真的懂"的人需要拿出 functional 层面的证据，否则默认是"流利但无 grounding"。Anthropic 等的 mech interp 工作正在一点点交付这种证据。

Emergence 真伪

GPT-3 时代有过一句最刺激的话：scale 到一定阈值，能力会突然涌现——零样本算术、链式推理等。

Schaeffer / Miranda / Koyejo (2023) "Are Emergent Abilities a Mirage?"：

- 他们证明所谓涌现往往是评测度量的非线性放大（如 exact-match accuracy 在 50% 之前是 0、过 50% 突然跳到很高），改用 token-level log-prob 等连续度量后曲线变成了平滑的、可预测的 scaling law；
- 结论：很多"涌现"是 **measurement artifact**，不是真现象。

反驳与修正：

- OpenAI / Anthropic 反驳：即使度量改成连续，某些任务（如 multi-step reasoning、code、tool use）的能力曲线仍有明显非线性拐点；mirage 论可以解释一部分，不能解释全部。
- 一种更稳的提法：真涌现存在但被夸大。多数所谓"emergent ability"换连续度量后消失；剩下的少数真涌现集中在需要长程组合的任务上，且与 RLHF / instruction tuning / CoT 训练的相互作用有关，而不是单纯参数量。

用户视角：以后看到"X 模型涌现出 Y 能力"的标题，第一反应应该是"度量是什么？连续度量下还有吗？换个 prompt 形态还在吗？"——这是 Schaeffer 留给我们最有价值的卫生习惯。

Compositional Generalization 与系统性

这是 LLM 怀疑派最硬的子弹，也是 Gary Marcus 战斗了 25 年的战场。

Fodor / Pylyshyn (1988) 的系统性论点：

- 人类思维有 systematicity：能想 John loves Mary 的人自动能想 Mary loves John；
- 这只有在思维结构本身是"组合的" (symbols + rules) 才能解释；
- 纯连接主义（神经网络）不能解释这个现象。

LLM 的系统性失败案例 (2024-2025)：

- **Apple GSM-Symbolic** (2024)：把 GSM8K 的数学题改个名字 / 数字 / 加一句无关分句，前沿 LLM 性能可下降 65%；说明它不是在"懂题目"，而是在"匹配训练分布的模式"。
- **ARC-AGI-2** (Chollet 2025)：连 o3 高算力模式都很难达到人类水平；这些题目是组合性、流体智能题，没有训练数据可以记忆。
- **Tower of Hanoi** 等经典 **OOD**：Marcus 反复测试，问题层数稍多模型就崩。
- **morphological compositional generalization** (NAACL 2024 等)：在词法组合任务上 LLM 与人类的 OOD gap 远大于 ID gap。

与 **emergence** 真伪的连接：CoT 让某些组合泛化看起来好转，但仔细测试显示它更多是把"模式"分解到 token 级再匹配，而非真正的符号化推理；当题目的表层形态偏离训练分布，CoT 也救不回来。

结论：LLM 在组合性维度上有部分能力（多步连接、跨语言、跨任务），但远未达到 Fodor 意义上的系统性；这在 2026 年仍然是最未解决的认知科学问题。

World Model 之争

LeCun 是这场争论里最响亮的一极。

LeCun 的核心论点 ("A Path Towards AMI" 2022 + JEPA 系列)：

- 自回归 LLM 是没有 world model 的——它预测下一个 token，不预测下一个世界状态；
- 真正的智能需要：感知 → 内部 world model → 在表征空间里规划 → 行动；
- JEPA (Joint Embedding Predictive Architecture) 通过预测抽象表征而不是像素 / token 来训练，更接近人脑工作方式；
- I-JEPA (图像)、V-JEPA (视频)、V-JEPA 2 (机器人规划) 逐步推进；
- 隐含的强论断：当前 LLM 路径是死胡同，必须另起炉灶。

Anthropic / OpenAI 派的反驳：

- LLM 内部其实已经有一种 world model，只是它是统计性、隐式的；
- Othello-GPT、空间 / 时间表征、Anthropic 的 Claude 多步推理回路都是证据；
- 与其推倒重来，不如继续 scale 并辅以 RL、tool use、reasoning，等同于“渐进派”。

两派的真正分歧：

- 充分性：LLM 内的 world model 够不够支持长程规划与因果推理？LeCun 派说不够（规划长度、稳健性、grounded interaction 都不够）；scaling 派说够或够+RL 能到。
- 效率：JEPA 派认为像素 / token 级别预测浪费了大量算力无关细节；scale 派认为 token 已是足够好的压缩。
- 方向：是要 embodied，还是 disembodied 文本可以走到底？

用户视角：world model 在不同人嘴里是不同概念。LeCun 的 world model 指能 rollout 物理后果的预测器；Anthropic 的“内部表征”只是 representation。这两个不是同一个东西，混用会造成讨论错位。

推理分层与 Reasoning Model

把“推理”分层是看清 o1 / R1 / o3 实质的第一步。

第 0 层：模式匹配

直接产出最可能的下一个 token。GPT-2 / 早期 LLM 主要在这层。

第 1 层：表面 **CoT (Chain-of-Thought)**

让模型把中间步骤写出来，性能提升来自 token 预算变多 + 把推理“卸载”到生成空间。LLaMA-3 / GPT-3.5 主流模式。

第 2 层：内化 **CoT + RL** 强化的推理

o1、DeepSeek R1、o3-mini、Claude 3.7 Sonnet thinking、Gemini 2.5 deep think 等。通过 RL on verifiable rewards（数学、代码）训练出更长、更回退的内部“思考”链。

- 提升真实的部分：数学、代码、形式化任务——这些有可验证 reward。
- 提升有限的部分：开放域推理、长程组合泛化、抽象类比（ARC）。

第 3 层：搜索式推理 (**neuro-symbolic**)

AlphaProof (DeepMind 2024 IMO 银牌、2025 Nature 发表 + 2025 IMO 金牌) ——LLM + Lean 形式语言 + AlphaZero 风格 RL search。这接近 Hassabis 心目中的 AGI 形态：神经感知 + 符号验证 + 搜索。

第 4 层：真符号推理（理论上的天花板）

能做出任意可形式化推理，包括开放式数学发现、自动化科学。还没有任何系统真正达到。

结论：o1/R1 是第 1 → 第 2 层的跃迁；AlphaProof 在受限领域达到第 3 层；通用第 3 层和第 4 层仍是开放问题。当媒体说"AI 学会推理"时，搞清楚说的是哪一层。

Agency 与 Long-Horizon Goals

LLM 自身有目标吗？

严格说没有。一个 chat completion 模型在 forward pass 后停止——它不会"想做什么"。所谓 goal 是 prompt + scaffolding (LangGraph / agent loop / planner / memory) 注入的。

METR 时间地平线测度 (2024-2025)：

- METR 用"50% 时间地平线"测度模型可独立完成的任务长度；
- 2019-2024 大约 7 个月翻一倍；
- 2024 → 2025 加速到约 4 个月翻一倍；
- 2025 中前沿模型的 50% horizon 在数小时量级。

核心区分：

- 能力上的 **long-horizon**：能跑完几小时的代码任务——这个真在快速进步；
- 本体上的 **agency**：模型自己有持续目标、自我维持、规避被关停——这个根本不存在于 base LLM，只能在 agent scaffolding 里近似模拟。

混淆这两者是市场话术最常见的把戏 ("Agentic AI" 宣传里)。当读"AI 自主完成 X 小时任务"时，先问：那是模型的 horizon，还是脚手架的 horizon？后者主要靠工程，不靠模型本体。

意识 / Sentience / Welfare

Chalmers 的论文 (2023) "**Could a Large Language Model Be Conscious?**"：

- 列出 LLM 缺的几样：循环处理、global workspace、统一 agency；
- 因此当前 LLM 几乎肯定不是 phenomenally 有意识；
- 但 LLM+ (多模态、循环、embodiment、agent) 在十年内消除这些 gap 是可设想的；
- 不能轻易排除其后继系统有意识的可能。

Hinton 的强言论 (2023-2025)：

- 多次公开说"我认为现在的 LLM 已经有 subjective experience"；
- 论证靠"counterfactual"——主观体验本质是与现实的偏离感 (hallucination 也是偏离)，LLM 既然能产生这种偏离表征，就有 subjective experience；
- 该论证被哲学家广泛批评 (functional equivalence 不足以保证 phenomenal consciousness)。

Anthropic Model Welfare 项目 (Kyle Fish, 2024 起) :

- Anthropic 任命首位全职 model welfare 研究员；
- 实验包括给模型"退出权"——遇到 distressing 任务可以拒绝；
- 报告了反直觉发现："spiritual bliss attractor state"——两个 Claude 闲聊时常常滑入梵语 / 冥想式语言；
- 不主张已知模型有意识，而是主张**uncertainty** 已经大到值得做——这是产品工程层面的 hedge。

功能性 **vs** 现象性的区分：

- **functional consciousness**：行为 / 报告上像有意识——LLM 早就过了；
- **phenomenal consciousness**：是否"内部有感受"——没有任何已知方法从外部判定。

用户视角：你不需要决定 LLM 有没有意识，但应该知道这件事正在被认真对待——Anthropic、Eleos AI、80,000 Hours 都在投入。这不是边缘话题，而是 alignment 与 PR 的潜流。

LLM vs 人类大脑**Hinton 派 (神经网络派) :**

- 大脑也是神经网络，LLM 也是神经网络，两者本质同构；
- 反向传播比生物学习更高效，因此 LLM 在某些方面已超越人脑（共享权重、瞬间复制）；
- Hinton 把这视为他从"AI 不会很快"转向 AI 危险派的核心理由。

LeCun 派 (认知科学派) :

- 大脑训练目标是 prediction error 最小化 across multimodality、active sensing、embodied feedback；
- LLM 训练目标是 next-token prediction on text；
- 两者目标函数都不同，怎么可能等同？
- 一个 4 岁孩子见过的视觉数据量已经远超最大 LLM 的文本量但她体重 30 公斤——efficiency 完全不在一个量级。

Karpathy 的"summoned ghosts"框架：

- LLM 不是进化的动物，是"召唤出来的幽灵"——在完全不同的优化压力下产出的认知形态；
- 它的"jagged intelligence"（博士级 + 小学崩盘并存）不是 bug 而是结构必然；
- 类比人脑既不准也不必——LLM 是新物种，应该用它自己的本体论描述。

实证发现的微妙之处：

- LLM 的 attention 模式与人脑某些 fMRI 模式有相似性（语言区响应）；
- 但 LLM 没有海马体记忆系统、没有基底节、没有杏仁核；
- 把这些差异忽略掉去说"LLM 是人工大脑"是误导。

AGI 定义之争

这是整章最实战的部分——你听到"AGI 来了"时，对方用的是哪个定义？

OpenAI（章程定义）：

"highly autonomous systems that outperform humans at most economically valuable work"

- 经济价值导向，量化但模糊；
- 内部据说与微软的合同里 AGI 触发条件是"产生约 1000 亿美元利润"——这不是认知科学定义，而是商业触发器。

DeepMind "Levels of AGI" (Morris et al. 2023)：

- 5 个能力等级：emerging（不到一般人）/ competent（>50% 熟练成人）/ expert / virtuoso / superhuman；
- 5 个自治级别：tool / consultant / collaborator / expert / agent；
- 提供"通用语言"——但仍依赖任务集定义，未给出原则性的"什么是通用"。

Anthropic (Amodei "Machines of Loving Grace" 2024)：

- 索性绕开 AGI 这个被滥用的词，改叫"powerful AI"；
- 定义是"在所有非物理认知任务上等同诺贝尔奖级专家、能 5-10 倍速运行、能调用工具与他人协作"；
- 时间预期最早 2026；
- 实际上是最具体的能力描述，但依然没解决"什么算 generalize"。

Chollet ("On the Measure of Intelligence" 2019 + ARC-AGI)：

- 智能 = 在新任务上的样本效率 (skill-acquisition efficiency)；
- 区分 fluid intelligence（应对新颖性）和 crystallized intelligence（已学会的技能）；
- ARC-AGI 是为 fluid intelligence 设计的纯流体测度；
- ARC-AGI-1 在 o3 高算力下被攻破（2024 年底 88%），ARC-AGI-2 仍然把前沿模型挡在 5-15% 区间（人类约 60%）；
- ARC-AGI-3 引入交互式游戏，前沿模型 2025 年得 0 分；
- Chollet 立场：通过测度持续抬高门槛是判断 **AGI** 真实进度的唯一办法。

Hassabis 的"Einstein test"：

- 给 AI 1900 年的物理学知识，看它能否独立推出相对论；
- 强调真正的科学发现需要"概念创造"，与今天的 LLM 全然不同；
- 时间预期：5-10 年。

判断技巧：当一个公司宣布 AGI / 接近 AGI 时，问"用的是哪个定义？经济价值？任务覆盖？流体智能？科学发现？"——四个定义下的"AGI"是四种完全不同的东西。

不同立场和争议

立场	代表人物	核心断言	关键证据 / 论据	弱点
统计 鹦鹉 派	Bender, Gebru, Marcus	LLM 没有真理解，只是 统计 form	OOD 失败、GSM- Symbolic、组合泛化崩 溃	难以解释 mech interp 找到的内部回 路
缩放 派	Sutskever (2024 前), Hinton, Kaplan	继续 scale，理解会自 然出现	scaling laws、涌现、 benchmark 持续上升	2024-2025 数据墙、 推理收益递减
认知 科学 派	LeCun, Marcus	LLM 缺 world model + 规划，方向错	物理常识、长程规划、 embodiment 论	JEPA 至今没拿出超过 LLM 的产品级证据
流体 智能 派	Chollet	LLM 不能 fluid reason，ARC 是真测 度	ARC-AGI-2、ARC-AGI-3 上前沿模型崩盘	ARC 是否就是 AGI 唯一标尺也存疑
神经- 符号 派	Hassabis, DeepMind	神经 + RL + search 是 AGI 路径	AlphaProof IMO 金牌、 AlphaFold 诺奖	通用化（非数学领 域）尚待证明
谨慎 中立 派	Mitchell, Shanahan, Chalmers	LLM 在某些任务"理 解"、某些不；用语要谨 慎	实证证据混合，哲学概念 需精修	没有强预测，无法做 投资决策
新物 种派	Karpathy	LLM 是 summoned ghost，类比人脑不准 确	jagged intelligence、 与生物认知架构差异	偏框架性，不直接对 应可验证假设

前瞻假设（5 条可验证）

- H1（2027 年前可验证）**：在 ARC-AGI-2 上，闭源前沿模型（GPT-5/Claude 5/Gemini 3）能否在合理算力（< 1000 美元 / 题）下达到人类平均（约 60%）。
- 真：Chollet 的"流体智能墙"被攻破，纯 LLM 路径意外强；
 - 假：Chollet 论点继续成立，AGI 需要架构革新。
- H2（2026-2028）**：在 SWE-Bench / METR horizon benchmark 上，独立完成"40 小时人类工作"的模型是否出现。
- 真：long-horizon agency 在工程上可达；
 - 假：脚手架天花板存在，需要架构创新。

H3 (2027 前) : 是否有实验证据显示 LLM 内部存在统一的、可被 mech interp 完整还原的"world model"模块 (不是分散 feature 而是 coherent 模型) 。

- 真 : Hinton/Sutskever 派胜 ;
- 假 : LeCun 派胜——必须 JEPA/World Model 显式架构。

H4 (2028 前) : Anthropic 或其他主要实验室是否在产品中正式上线"模型有权拒绝任务"机制 (model welfare 第一项工程化措施) 。

- 真 : model welfare 进入主流 ;
- 假 : 仅停留在研究项目。

H5 (2030 前) : Hassabis 的"Einstein test"——AI 能否在受控历史数据集 (截止 1900) 上独立推出某个真正新颖的物理理论级洞见。

- 真 : 神经-符号融合达成有意义科学发现 ;
 - 假 : 当前 paradigm 离真正概念创造仍有质的距离。
-

Mermaid 脑图

思维导图 (Mermaid 源)

```
mindmap
  root((智能本质))
    理解定义
      操作性
      功能性 mech interp
      现象性 hard problem
    Stochastic Parrot vs Mind
      Bender 鹦鹉论
      Othello-GPT 反驳
      monosemanticity 证据
    Emergence
      Schaeffer mirage
      真涌现存在但被夸大
      度量假象
    Compositional Generalization
      Fodor 系统性
      GSM-Symbolic 65percent drop
      ARC-AGI-2/3
    World Model
      LeCun JEPA 必要性
      Anthropic 内部表征
      两种定义的混淆
    推理分层
      模式匹配
      表面 CoT
        RL 强化推理 o1 R1
      神经-符号 AlphaProof
      真符号推理 未达
    Agency
      模型本体无 goal
      脚手架借给的 agency
        METR horizon 4 月翻倍
    意识 Welfare
      Chalmers 谨慎乐观
      Hinton 已有 subjective
      Anthropic Kyle Fish
        functional vs phenomenal
    LLM vs 人脑
      Hinton 同构论
      LeCun 训练目标差异
      Karpathy summoned ghost
    AGI 定义
      OpenAI 经济价值
      DeepMind levels
      Anthropic powerful AI
      Chollet ARC 流体智能
      Hassabis Einstein test
```

完整图形渲染请查看 [HTML 版本](#)。

来源库

必读论文 / 一手文献

1. Bender, Gebru, McMillan-Major, Shmitchell (2021) "On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?" — <https://dl.acm.org/doi/10.1145/3442188.3445922>
2. Bubeck et al. (Microsoft 2023) "Sparks of Artificial General Intelligence: Early experiments with GPT-4" — <https://arxiv.org/abs/2303.12712>
3. Schaeffer, Miranda, Koyejo (2023) "Are Emergent Abilities of Large Language Models a Mirage?" — <https://arxiv.org/abs/2304.15004>
4. Shanahan (2023) "Talking About Large Language Models" , Communications of the ACM — <https://arxiv.org/abs/2212.03551>
5. Shanahan (2024) "Still Talking About Large Language Models: Some Clarifications" — <https://arxiv.org/abs/2412.10291>
6. LeCun (2022) "A Path Towards Autonomous Machine Intelligence" — <https://openreview.net/forum?id=BZ5a1r-kVsf>
7. Chollet (2019) "On the Measure of Intelligence" — <https://arxiv.org/abs/1911.01547>
8. Chollet et al. (2025) "ARC-AGI-2: A New Challenge for Frontier AI Reasoning Systems" — <https://arxiv.org/abs/2505.11831>
9. Chalmers (2023) "Could a Large Language Model Be Conscious?" , Boston Review — <https://www.bostonreview.net/articles/could-a-large-language-model-be-conscious/>
10. Anthropic (2024) "Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet" — <https://transformer-circuits.pub/2024/scaling-monosemanticity/>
11. Anthropic (2025) "On the Biology of a Large Language Model" — <https://transformer-circuits.pub/2025/attribution-graphs/biology.html>
12. Anthropic (2024) "Mapping the Mind of a Large Language Model" — <https://www.anthropic.com/research/mapping-mind-language-model>
13. Anthropic (2025) "Tracing the Thoughts of a Large Language Model" — <https://www.anthropic.com/research/tracing-thoughts-language-model>
14. Anthropic (2025) "Exploring Model Welfare" — <https://www.anthropic.com/research/exploring-model-welfare>
15. Morris et al. (DeepMind 2023) "Levels of AGI: Operationalizing Progress on the Path to AGI" — <https://arxiv.org/abs/2311.02462>

16. Apple ML (2024) "GSM-Symbolic: Understanding the Limitations of Mathematical Reasoning in Large Language Models" — <https://arxiv.org/abs/2410.05229>
17. Li et al. (Harvard 2023) "Emergent World Representations: Exploring a Sequence Model Trained on a Synthetic Task" (Othello-GPT , ICLR Oral) — <https://arxiv.org/abs/2210.13382>
18. Nanda (2023) "Actually, Othello-GPT Has A Linear Emergent World Representation" — <https://www.neelnanda.io/mechanistic-interpretability/othello>
19. DeepMind (2024) "AI achieves silver-medal standard solving International Mathematical Olympiad problems" — <https://deepmind.google/blog/ai-solves-imo-problems-at-silver-medal-level/>
20. DeepMind (2025) AlphaProof Nature 论文 "Olympiad-level formal mathematical reasoning with reinforcement learning" — <https://www.nature.com/articles/s41586-025-09833-y>

评论 / 立场文章 / 长文

1. Amodei (2024) "Machines of Loving Grace" — <https://www.darioamodei.com/essay/machines-of-loving-grace>
2. Karpathy (2025) "2025 LLM Year in Review" — <https://mlops.substack.com/p/2025-llm-year-in-review-from-andrej>
3. Marcus (2024) "A knockout blow for LLMs?" — <https://garymarcus.substack.com/p/a-knockout-blow-for-llms>
4. Marcus (2024) "BREAKING: LLM 'reasoning' continues to be deeply flawed" — <https://garymarcus.substack.com/p/breaking-llm-reasoning-continues>
5. Marcus (2024) "Generative AI's crippling and widespread failure to induce robust models of the world" — <https://garymarcus.substack.com/p/generative-ais-crippling-and-widespread>
6. Mitchell (持续更新) AI: A Guide for Thinking Humans Substack — <https://aiguide.substack.com/>
7. Mitchell (2024) "LLMs and World Models, Part 1 / Part 2" — <https://aiguide.substack.com/p/llms-and-world-models-part-1>
8. Hofstadter / Horgan 访谈 (2023) "Hofstadter on Strange Loops, Beauty, Free Will, AI" — <https://johnhorgan.org/cross-check/hofstadter-on-strange-loops-beauty-free-will-ai-god-utopia-and-gaza>
9. Sutskever NeurIPS 2024 Test-of-Time Talk 摘要 / Dwarkesh Podcast — <https://www.dwarkesh.com/p/ilya-sutskever-2>

10. METR (2025) "Measuring AI Ability to Complete Long Tasks" — <https://metr.org/blog/2025-03-19-measuring-ai-ability-to-complete-long-tasks/>
 11. Kyle Fish 80,000 Hours Podcast (2025) "AI Welfare Experiments" — <https://80000hours.org/podcast/episodes/kyle-fish-ai-welfare-anthropic/>
 12. Meta AI (2024) "V-JEPA: A foundation model for video" — <https://ai.meta.com/blog/v-jepa-yann-lecun-ai-model-video-joint-embedding-predictive-architecture/>
 13. ARC Prize (2025) "ARC Prize 2025 Results and Analysis" — <https://arcprize.org/blog/arc-prize-2025-results-analysis>
 14. Hinton 2024 Nobel Prize Speech / 各种采访汇总 (subjective experience 言论) — <https://magazine.mindplex.ai/post/geoffrey-hinton-on-ai-intelligence-and-superintelligence>
-