

AI mindset explore — 个人 AI 认知框架

这不是一份一次性报告，而是一套可持续维护的认知工具。

10 个独立视角并行深挖，覆盖技术本质 / 操控术 / 工程实践 / 行业替代 / 投资格局 / 个人工作流 / 基础设施 / 安全治理 / 智能本质 / 前瞻争议。

每章独立成文，互有 overlap，不强求一致。允许相左观点并解释立场背景。

这是什么 / 不是什么

这是：一套让你日后看到任何新模型 / 新工具 / 新观点时，能快速定位、判断含金量、追问背景的
思考脚手架。

- 不是：
- 不是一次性的报告（永远在迭代）
 - 不是"标准答案"（每章都有相左观点和原因）
 - 不是技术教程（不教你怎么跑代码）
 - 不是行业八卦（每条结论必须有引用）

怎么用

你正在做什么	翻哪章
看到新模型 / 新论文，想判断是不是真本质突破	01 + 09
决定要不要在产品里上 multi-agent / 复杂编排	02 + 03
评估某个 AI 创业公司是不是"真公司"	04 + 05
决定哪些工作交给 AI、哪些不该	06
判断算力 / 电力 / 地缘新闻的真实分量	07
判断 AI safety 新闻是真问题还是炒作	08
解读名人 AI 预测，识别立场偏置	10
重新思考你的下一个 AI 项目的边界	03 + 06 + 09

10 章导航

#	章节	一句话总览
01	技术演进与本质	真本质突破只有 4 件：Transformer / Scaling Laws / RLHF→RLVR / Function calling→Computer use
02	操控术分层演进	L0-L7 上一层失效→下一层逃生；技巧保鲜期只有一代模型
03	工程实践与架构模式	Eval 是真护城河；最珍贵建议是「最简单的 while 循环」
04	行业替代地图	替代发生在 task 层不是 industry 层；70/30 是平衡态
05	投资与商业模式	短期基础设施吃肉、中期模型层下沉、长期 vertical AI 显形
06	个人工作流与认知重塑	AI 是平权器但放大「普通」；从生成转向验证
07	基础设施、算力、地缘	瓶颈在沿供应链上移：HBM → ASML → 电网变压器
08	安全、对齐、伦理	实证转折 + 治理倒退；adversarial training 反让 backdoor 更隐蔽
09	认知科学与智能本质	「理解」之争是定义之争；agency 是脚手架借的
10	前瞻与争议	派别分歧根源是先验假设错位 + P&L 利益绑定

每章结构相同：一句话总览 / 关键句提纲 / 深度展开 / 不同立场和争议（含每派的立场背景） / 5-10 条可验证前瞻假设 / Mermaid 脑图 / 15-35 条来源链接。

顶层框架图

思维导图 (Mermaid 源)

```
mindmap
  root((AI mindset))
    技术维度
      技术本质 [01]
      操控术分层 [02]
      工程模式 [03]
      智能本质 [09]
    生态维度
      行业替代 [04]
      投资格局 [05]
      个人 workflow [06]
      安全治理 [08]
    物理维度
      算力地缘 [07]
    时间维度
      前瞻争议 [10]
```

完整图形渲染请查看 [HTML 版本](#)。

四个维度的提问角度不同：

- 技术维度问"这是什么"
- 生态维度问"谁会赢 / 谁会被淘汰"
- 物理维度问"什么是真瓶颈"
- 时间维度问"何时发生 / 谁的预测可信"

任何 AI 新闻都至少落在某一维度上，找对维度才能问对问题。

跨视角共识 (10 个独立 **agent** 都指向同一件事)

1. **Test-time compute** 是新 **scaling** 轴 — pretraining loss 与能力跃升解耦，新跃升来自 RL + inference compute；"模型规模"作为讨论核心词正在过时 (01 / 02 / 07 / 10)
2. **Eval** 是真护城河，**prompt** 是表面 — 操控术细节技巧在贬值，eval 工程在升值 (02 / 03)
3. **METR horizon length** 是 **agent** 进展唯一干净指标 — 任务时长每 4 个月翻倍 (01 / 02 / 09)
4. 简单 > 复杂 — Anthropic 公开建议先用裸 while 循环再上框架；multi-agent 大多是工程问题误诊 (02 / 03)
5. 物理瓶颈正在显形 — 电力 / HBM / 变压器 lead time 已成事实瓶颈，不是钱能 24 个月内解决的 (05 / 07)

- 6. **C** 端闭环成战略资产 — 合成数据时代，无 C 端用户互动闭环的玩家（Meta / xAI）有结构性劣势（05 / 07）
- 7. **Anthropic** 已悄悄超 **OpenAI** 营收 — \$30B vs \$25B 年化（2026.4），“AI = OpenAI”叙事被打破（04 / 05）
- 8. 替代有平衡态，“100% 替代”叙事都会回滚 — Klarna 70/30 模型可推广到法律 / 医疗 / 教育（04 / 06）

跨视角根本分歧

议题	阵营 A	阵营 B	阵营 C
LLM 是否通向 AGI	Sutskever / Hinton / Anthropic : 是	LeCun : 缺 world model	Marcus : scale 解决不了系统性
AGI 时间表	Aschenbrenner: 2027	Amodei: 2026-2030	Acemoglu: 影响要 30 年
复杂操控术价值	LangGraph / CrewAI 派	Anthropic 简单派	"全靠 base model" 派
RAG 命运	long-context 取代论	hybrid + rerank 长存	agentic RAG 是终态
wrapper trap	a16z : 应用层会赢	Stratechery : 模型公司下沉	80% 薄壳必死共识
安全紧迫度	Anthropic / Bengio : 真且急	LeCun / 多数 ML 派 : 炒作	AI Snake Oil : 混淆近期 vs x-risk
capex 泡沫	Goldman / Zitron : 撞墙	a16z / Sequoia : 真实价值	Cahn : \$600B 缺口
经济影响测量	Acemoglu : +0.7% TFP / 10 年	Aschenbrenner : GDP 倍数	Newport : 30 年慢扩散

分歧的根源往往不是事实差异，而是 (a) 测量对象不同 (b) 先验假设不同 (c) 利益绑定不同。

最反直觉洞察 Top 12（精选）

#	洞察	章节
1	"涌现"是测量假象（Schaeffer 2023）—— 换连续指标就平滑	01
2	pretraining loss 与能力跃升解耦；判断新发布要看动没动 RL / agentic 这条新轴	01
3	CoT 在 reasoning model 上反而扣分（o1 / o3 加 "think step by step" 模板正确率下降）—— 提示工程的具体技巧保鲜期只有一代模型	02
4	Computer use 是 L4 退化补丁不是进化 —— 长期会被 MCP / "build for agents" 反向吃回	02
5	Long context 没杀死 RAG，反而强化它 —— citation accuracy 在长上下文中显著下降	03
6	放射科岗位反而 +5%（BLS 2024-2034）—— 老龄化把需求放大得比 AI 替代效率高	04
7	Klarna 客服打脸：70/30 是真平衡态 —— 所有"100% 替代"故事 2026-27 都会回滚	04
8	AI 是平权器但放大的是"普通"（BCG 实验：下半区 +43% vs 上半区 +17%）—— 精英真护城河变成"AI 没法教的东西"	06
9	数据墙让 C 端产品成核心战略资产 —— Meta / xAI 这类无 C 端闭环的玩家有结构性劣势	07
10	Adversarial training 让 sleeper agent 更隐蔽而非移除 backdoor —— 公开红队结果可能反过来教模型如何隐藏失败	08
11	"AI agency 在进步"是错觉 —— 翻倍的是脚手架 + 模型组合的 horizon，不是模型本体；alignment 真正杠杆点在 agent loop 设计而非模型权重	09
12	AGI 时间表 ≠ 影响时间表（Cal Newport）—— 可能像电力 30 年才见 productivity；即使 Aschenbrenner 时间表对，Acemoglu 经济学也可以同时对	10

信念校准清单（你日后看到任何 AI 内容，过这 12 个问题）

- 1. 测量对象是什么？是 base model 进步、还是 scaffolding + model 组合的进步？（参 09）
- 2. 指标连续吗？涌现叙事有没有用 exact-match 这种非线性指标在欺骗你？（参 01）
- 3. 新跃升来自哪条轴？Pretraining / RL / inference compute / tool use？（参 01）
- 4. 替代的是 **task** 还是 **industry**？70/30 平衡点是什么？（参 04）
- 5. 物理瓶颈是什么？HBM / 变压器 / 电力？（参 07）
- 6. 作者有没有 **C** 端闭环？没有的话长期合成数据时代会出问题（参 07）
- 7. **Eval** 怎么做的？没说就是没做（参 03）
- 8. **Agent** 架构有多复杂？越复杂越要警惕（参 02 / 03）

- 9. 作者今年的 **P&L** 怎么依赖于这个判断被相信？（参 10）
- 10. 是离职创办者吗？多了"卖差异化叙事"的偏置（参 10）
- 11. 用的是哪个 **AGI** 定义？OpenAI / DeepMind / Chollet 定义不同（参 09 / 10）
- 12. 时间表说的是能力还是影响？两者可能差 20-30 年（参 10）

把这 12 个问题打印出来贴在显示器旁边。

持续维护协议

这套框架是活资产，不是文物。建议节奏：

频率	动作
每周	把本周新读的 1-3 篇高质量内容塞进对应章节末尾的 changelog
每月	检查每章的"前瞻假设"是否被证伪 / 证实
每季度	复核 Top 12 反直觉洞察是否需要修正 / 淘汰 / 替换
遇到大事件	新模型发布 / 重要 talk / 重大政策时立即追加章节末 changelog
发现新维度	现有 10 章覆盖不了的新角度，加 11、12……章

关键纪律：永远不要删历史（哪怕被打脸）。被证伪的假设比被证实的更值钱——它告诉你哪种推理模式不该用。

来源系谱（10 类必读源）

每章末尾有详细 source 表（15-35 条 / 章）。整体看，10 类核心源：

类型	核心源
技术研究	Anthropic Research, OpenAI, DeepMind, Karpathy, Sutskever, Jason Wei
工程实践	Hamel Husain, Eugene Yan, Sebastian Raschka, Latent Space podcast, Anthropic eng
操控术	Lilian Weng, Simon Willison, Anthropic "Building Effective Agents"
行业 / 投资	a16z, Sequoia, Stratechery (Ben Thompson), Bessemer, BCG, MIT NANDA
个人 workflow	Ethan Mollick, Andrej Karpathy, Tyler Cowen, Dan Shipper
基础设施	SemiAnalysis (Dylan Patel), Epoch AI, Dwarkesh Patel podcast
安全 / 对齐	Anthropic safety, Bengio, AI Snake Oil, AISI reports
认知科学	Melanie Mitchell, François Chollet, Murray Shanahan, Apple GSM-Symbolic team
前瞻 / 争议	Aschenbrenner, Kokotajlo (AI 2027), Acemoglu, Goldman Covello, Cal Newport
中文圈	量子位、机器之心、Founder Park、晚点 LatePost、宝玉 xp

反思你"做完一个项目后困惑"的根因

回到你最初提出这个项目的动因 —— 做完一个 AI 项目后，发现"理解 AI / 使用 AI / 与过去工作流的衔接"有大量边界没想清楚。

这套框架给出的诊断：

- 你卡住的不是 **AI** 能做什么"，而是 **AI** 能做的事中，哪些值得让它做" —— 这是第 06 章的核心，也是 04 章 task-level disruption 的角度
- 你直觉告诉你 **AI** 进步快"，但你没有衡量它的指标 —— 用 METR horizon length (01 / 02 / 09) 和 12 条信念校准清单作为新的尺
- 你担心 **AI** 替代你的工作，但更应该担心的是认知卸载副作用 (06) —— "从生成转向验证"才是真正难的认知模式
- 你看到大量 **AI** 新闻不知道哪些重要，是因为没有立场过滤器 —— 第 10 章给出"读 AI 预测先看作者今年损益表"的纪律
- 你的下一个项目应该问的不是"用什么模型 / 框架"，而是"我要做的任务在 **jagged frontier** 的哪一侧、要用哪一层操控术、**eval** 怎么做、谁是 **C** 端闭环" —— 这就是 02 / 03 / 04 / 06 / 07 联合给的 checklist

changelog

- **v0.1 (2026-05-10)** — 初始 10 章 + README 整合。10 个独立 agent 并行检索 2024-2026 一手资料，写入约 3700 行 / 约 5 万字内容。
-

"被证伪的假设比被证实的更值钱。"